

Co váží „typický“ savec?

První setkání s daty a popisem jedné proměnné

26. července 2026

Obsah

1 Vítejte v biostatistice	3
1.1 Jak jsou kurz a materiály uspořádány	3
1.2 Kde najdete materiály a informace	3
1.3 Doporučená literatura	4
1.4 Účast, zápočet a zkouška	5
2 Jak číst skripta	5
2.1 Doporučený způsob čtení	5
2.2 HTML a PDF	6
2.2.a HTML	6
2.2.b PDF	6
2.3 Co znamenají rámečky a další značky	6
2.4 Jak číst kód	7
3 Výsledky učení	7
4 Datová detektivka: kolik váží „typický“ savec?	7
4.1 Hlasování	8
5 Od měření k tabulce a vektoru	8
5.1 Čtyři skutečné záznamy	8
5.2 Stejně hodnoty jako vektor v R	9
5.3 První kontrola vektoru	9
5.4 Jak vypadá celý datový rámec?	10
6 Vizualizace dat: nejdříve se podívejte	12
6.1 Proč začínáme grafem?	12
6.2 Bodový graf	12
6.2.a Graf	12
6.2.b Kód v R	12
6.3 Hodnoty seskupené do intervalů	13
6.3.a Graf	13
6.3.b Kód v R	14
6.4 Graf hustoty	15
6.4.a Graf	15
6.4.b Kód v R	16
6.5 Tři pohledy na tutéž proměnnou	16

7	Deskriptivní statistiky: čísla, která patří ke grafu	17
7.1	Malý skutečný příklad	17
7.2	Minimum a maximum	17
7.2.a	Minimum	18
7.2.b	Maximum	18
7.3	Aritmetický průměr	18
7.4	Prostřední hodnota seřazených dat	20
7.5	Průměr a medián: návrat k titulku	20
7.5.a	Původní osa	21
7.5.b	Přiblížení pomocí logaritmické osy	21
7.6	Percentily a kvartily	22
7.7	Prostřední polovina hodnot	23
7.8	Od středu k variabilitě	24
7.9	Jak daleko hodnoty leží od středu	25
7.10	SD jako vzdálenost na grafu	29
7.11	Stejná průměrná mzda, jiná SD	29
7.12	Které dvojice souhrnů patří k sobě?	30
8	Statistiky jako vizualizace: stavíme graf ze souhrnů	30
8.1	Krok 1: jednotlivé hodnoty a medián	31
8.2	Krok 2: krabice je IQR	31
8.3	Krok 3: vousy a body za nimi	31
8.4	Výsledný krabicový graf	33
8.4.a	Graf	33
8.4.b	Kód v R	33
8.5	Když chceme vidět tvar: houslový graf	34
9	Typy proměnných: zobecnění na konci	37
9.1	Numerická spojitá proměnná	38
9.1.a	Bodový graf	39
9.1.b	Histogram	39
9.1.c	Graf hustoty	40
9.1.d	Krabicový graf	40
9.2	Numerická diskrétní proměnná	40
9.2.a	Bodový graf četností	42
9.2.b	Sloupcový graf	42
9.3	Kategoriální nominální proměnná	42
9.3.a	Četnosti	44
9.3.b	Podíly	44
9.4	Kategoriální ordinální proměnná	45
9.5	Procvičení: určete typ proměnné	47
9.6	Přehled: od typu proměnné k vhodnému popisu	48
10	Shrnutí	49
10.1	Závěrečná otázka	49
11	Most k další lekci	49

1 Vítejte v biostatistice

Biostatistika pomáhá převést biologickou otázku na postup, který lze zkontrolovat: **co jsme pozorovali, co jsme změřili, jak jsme data zobrazili a co z nich smíme tvrdit**. Budeme se opakovaně vracet k cestě:

biologická otázka → data → graf → model → kontrola → interpretace

V této lekci zůstaneme u prvního statistického kroku: jak poctivě popsat **jednu proměnnou**.

1.1 Jak jsou kurz a materiály uspořádány

Součást	K čemu slouží	Jak s ní pracovat
Přednáška	Společné přemýšlení nad biologickou otázkou, grafy a interpretací	Hlasujte, porovnávejte vysvětlení a ptejte se, co výsledek skutečně znamená.
Praktické cvičení	Samostatná práce s daty a R s podporou vyučujících	Kód zkoušejte, měňte a průběžně vysvětľujte vlastními slovy.
Tyto podklady	Úplnější vysvětlení a reprodukovatelné příklady	Čtete je před výukou nebo se k nim vraťte při opakování.
Výstupy v HTML a PDF	Dvě podoby stejného obsahu	HTML nabízí interaktivní prvky; PDF se hodí pro souvislé čtení a poznámky.

1.2 Kde najdete materiály a informace

Hlavním veřejným rozcestníkem je [HUB kurzu](#). Na stránce [Materiály](#) najdete pro každou zveřejněnou lekci stabilní studentské verze:

Materiál	Dostupné podoby	K čemu slouží
Skripta	HTML; PDF pro tisk	Úplnější výklad pro přípravu, samostudium a opakování
Prezentace	HTML; PDF pro tisk	Stručnější záznam společné práce na přednášce
R skripty	soubory s kódem	Praktická práce s daty v R
Data	datové soubory	Data potřebná pro praktickou práci a samostatné procvičování

1.3 Doporučená literatura

K absolvování kurzu **stačí HUB, skripta a prezentace**. Literatura je nepovinná a hodí se, když chcete látku vidět z jiného úhlu nebo si ji procvičit na dalších příkladech. Požadavky kurzu určují materiály na HUBu, ne uvedené knihy.

Zdroj	K čemu se hodí
Lepš, J., Šmilauer, P. (2024): <i>Biostatistika</i> , 2. vyd. (česky)	Česká učebnice statistiky pro biology s postupy v programech Statistica a R
Crawley, M. J. (2013): <i>The R Book</i> , 2. vyd.	Rozsáhlá příručka k R a statistickým postupům v něm
Dalgaard, P.: <i>Introductory Statistics with R</i>	Stručný úvod do statistiky s ukázkami v R
Wickham, H., Çetinkaya-Rundel, M., Grolemund, G.: <i>R for Data Science</i> , 2. vyd. (anglicky, online)	Práce s daty a grafy v R
Ismay, C., Kim, A. Y., Valdivia, A.: <i>ModernDive</i> , 2. vyd. (anglicky, online)	Statistické myšlení a R krok za krokem

Online zdroje mohou používat jiný zápis R kódu než naše skripta. Úplný a aktuální seznam literatury najdete na stránce [Jak pracovat s materiály](#) na HUBu kurzu.

Různé kurzové systémy mají odlišné úlohy:

Systém	K čemu slouží
HUB	Aktuální informace o kurzu, rozvrh, pravidla hodnocení, veřejné studijní materiály a archiv semestrů
SIS	Zápis do předmětu a skupin, termíny zkoušek a oficiální studijní evidence
Moodle	Testy, zadání, odevzdávání, individuální výsledky a oznámení určená zapsaným studentům

1.4 Účast, zápočet a zkouška

Účast na přednáškách a praktických cvičeních je dobrovolná. Ve výuce získáte vysvětlení, podporu a zpětnou vazbu; při samostudiu najdete požadované znalosti ve skriptech a R skriptech. **Stejně kompetence však musí prokázat každý.**

- **Praktický zápočet** ověřuje, zda dokážete samostatně provést a vysvětlit základní analýzu malého datasetu v R.
- **Závěrečná zkouška** ověřuje porozumění analytickým rozhodnutím, interpretaci, diagnostice a nejistotě, nikoli psaní syntaxe z paměti.

AI při učení a hodnocení

Při učení můžete AI používat. U zápočtu a zkoušky pracujete samostatně bez internetu a AI.

Aktuální [pravidla hodnocení](#) jsou uvedena na HUBu. Termíny zkoušek a zápis na ně jsou v SIS. Termíny praktického zápočtu, odevzdávání, individuální výsledky a neveřejné organizační pokyny jsou v Moodle.

2 Jak číst skriptu

Tento dokument vznikl v Quarto, ale pro jeho čtení nemusíte Quarto znát ani instalovat. Stejný obsah dostáváte jako webovou stránku (HTML) a jako PDF. Liší se hlavně způsob, jak se v něm pohybujete.

2.1 Doporučený způsob čtení

1. Nejdříve si přečtete **výsledky učení**. Říkají, co byste po dokončení kapitoly měli umět.
2. U otázky, hlasování nebo úkolu se zastavte a zkuste odpovědět dříve, než budete pokračovat.
3. Graf nebo tabulku nejprve sami popište. Teprve potom čtete vysvětlení pod nimi.
4. Kód nemusíte memorovat. Sledujte, jaká data do něj vstupují, co s nimi příkaz dělá a jaký výsledek vrací.

5. Na konci se vraťte ke shrnutí a ověřte si, zda už dokážete vysvětlit hlavní myšlenky vlastními slovy.

2.2 HTML a PDF

Následující blok je zároveň ukázkou **záložek** (anglicky *tabs*, technicky *tabset*). V HTML mezi záložkami přepínáte kliknutím. V PDF jsou jejich obsahy vytištěné postupně za sebou.

2.2.a HTML

- Obsah na okraji stránky umožňuje přejít přímo do vybrané části.
- Projděte všechny záložky; současně je viditelná jen jedna.
- Rámeček s šipkou lze rozbalit a zase sbalit.
- U podtrženého odborného pojmu se po najetí kurzorem zobrazí stručné vysvětlení.
- U delšího bloku kódu se po najetí objeví tlačítko pro jeho zkopírování.

2.2.b PDF

- K orientaci slouží obsah, nadpisy a čísla stránek.
- Obsah všech záložek je vytištěný postupně, takže žádná část nechybí.
- Sbalitelné rámečky jsou rozbalené. U odpovědi se proto zastavte ještě před jejím přečtením.
- Význam odborných pojmů najdete v odkazovaném online slovníku.

2.3 Co znamenají rámečky a další značky

Značka	Jak s ní pracovat
Důležité	Hlavní pojem nebo závěr, který byste si měli odnést.
Pozor	Častá chyba nebo omyl. Zkontrolujte, že rozumíte, proč je daný postup problematický.
Poznámka	Podpůrné vysvětlení, příklad nebo kontext k hlavnímu výkladu.
Doplňující	Volitelná technická či rozšiřující informace. Při prvním čtení ji můžete přeskočit.
Otázka, Hlasování, Úkol	Výzva k vlastní odpovědi nebo činnosti. Nejříve se rozhodněte sami.
Odpověď	Kontrola po vlastním pokusu. V HTML ji otevřete kliknutím; v PDF je vytištěná.
Blok kódu a jeho výstup	Reprodukovatelný záznam postupu: co jsme zadali počítači a co počítač vrátil.
Podtržený odborný pojem	Odkaz na stručnou definici v online slovníku.

Význam nese především nadpis rámečku. Barva pomáhá s orientací, ale není nutné si ji pamatovat.

Doplňující: rozbalovací rámeček

Tento rámeček obsahuje volitelné rozšíření. V HTML jej můžete rozbalit; v PDF je vytištěný celý.

2.4 Jak číst kód

Každý řádek kódu, který vytváří výsledek, je v těchto materiálech viditelný, abyste mohli zkontrolovat, odkud se číslo nebo graf vzaly. Kód si nemusíte pamatovat. Při čtení se ptejte: **Jaká data vstupují? Co příkaz dělá? Jakou odpověď dostáváme?** Řádky začínající znakem `#` jsou komentáře pro čtenáře; počítač je nevykonává.

3 Výsledky učení

Po prostudování materiálů dokážete:

- vysvětlit, co v tabulce představuje jeden řádek, vytvořit z několika měření vektor v R a zkontrolovat jej pomocí `length()` a `head()`;
- přečíst bodový graf, histogram, graf hustoty, sloupcový graf a krabicový graf a popsat, co každý z nich ukazuje a skrývá;
- vysvětlit, proč data zobrazujeme dříve, než je shrneme jedním číslem;
- najít a interpretovat průměr, medián, kvartily, IQR, minimum, maximum a směrodatnou odchylku v číslech i na grafu;
- rozlišit spojitou, diskrétní, nominální a ordinální proměnnou a vybrat pro ni smysluplný první graf a shrnutí.

4 Datová detektivka: kolik váží „typický“ savec?

V tabulce máme hmotnost 83 druhů savců. Chceme odpovědět na zdánlivě jednoduchou otázku:

Kolik váží „typický“ savec v této tabulce?

Představte si, že ze stejných dat vyšly dva smyšlené novinové články.

Smyslený titulek A

Vědci spočítali: „Průměrný savec váží 166 kg.“

Smyslený titulek B

Jiná analýza stejných dat tvrdí: „Běžný savec váží jen 1,67 kg.“

4.1 Hlasování

Který titulek je podle vás nejpravděpodobněji správný?

- A) Správný je pouze titulek A.
- B) Správný je pouze titulek B.
- C) Obě čísla mohou být vypočtena správně.
- D) Bez dalších informací nelze rozhodnout.

Než budete pokračovat, vyberte jednu odpověď a napište si **jednu větu**, která ji zdůvodňuje. Zatím nepotřebujete znát názvy výpočtů. Potřebujete pouze rozpoznat, jaké informace vám chybějí.

Odpověď zatím odložíme

Nejdříve se naučíme sledovat cestu od měření přes tabulku a graf až k číselnému shrnutí. K oběma titulům se vrátíme ve chvíli, kdy budeme umět posoudit nejen výsledek výpočtu, ale také tvar dat.

5 Od měření k tabulce a vektoru

Výzkumníci studovali spánkové vzorce savců a zaznamenali, že gepard spí **12,1 hodiny za den**. Jedno takové pozorování můžeme zapsat jako jeden řádek tabulky: název druhu, sledovanou proměnnou, jednotku a naměřenou hodnotu.

Když podobná pozorování spojíme pro více druhů, vznikne datová tabulka. Dataset `msleep` obsahuje údaje o spánku a tělesné hmotnosti různých druhů savců a vychází z publikovaných biologických údajů. Každý řádek představuje **jeden zastoupený druh**, nikoli jednoho jednotlivého savce.

Představme si terénní nebo laboratorní práci, ze které taková tabulka vzniká. Výzkumníci pro každý druh shromáždí nebo převezmou měření, zapíší název druhu, jednotku a hodnotu a přidají je jako nový řádek. Naší jednotkou pozorování je zastoupený druh. My začneme jedinou proměnnou: **celkovou dobou spánku za den v hodinách** (`sleep_total`).

5.1 Čtyři skutečné záznamy

Podívejme se na první čtyři řádky. Hodnota v posledním sloupci je číslo, které by výzkumník zapsal do tabulky.

Druh (species)	Celkový spánek za den (sleep total; h)
Cheetah	12.1
Owl monkey	17.0
Mountain beaver	14.4
Greater short-tailed shrew	14.9

5.2 Stejné hodnoty jako vektor v R

Vektor je uspořádaná řada hodnot stejného základního typu. Čtyři hodnoty z tabulky můžeme do R zapsat pomocí funkce `c()`:

```
vec_spanek_ukazka <-  
  c(  
    12.1, # Cheetah  
    17.0, # Owl monkey  
    14.4, # Mountain beaver  
    14.9 # Greater short-tailed shrew  
  )  
  
vec_spanek_ukazka
```

```
[1] 12.1 17.0 14.4 14.9
```

Každá hodnota má stejný význam i jednotku: počet hodin spánku za den pro jeden zastoupený druh.

U celé tabulky nemusíme 83 čísel opisovat ručně. Vybereme sloupec `sleep_total` přímo z datového rámce:

```
# Vybereme jeden sloupec z původní tabulky.  
vec_spanek_h <-  
  ggplot2::msleep[["sleep_total"]]
```

5.3 První kontrola vektoru

Než začneme počítat nebo kreslit, zkontrolujeme dvě jednoduché věci:

1. **Kolik hodnot máme?**
2. **Vypadají první hodnoty jako očekávaná měření v hodinách?**

```
length(vec_spanek_h)
```

```
[1] 83
```

```
head(  
  x = vec_spanek_h,  
  n = 10  
)
```

```
[1] 12.1 17.0 14.4 14.9 4.0 14.4 8.7 7.0 10.1 3.0
```

`length()` potvrzuje počet hodnot. `head()` ukazuje začátek vektoru, takže rychle odhalíme například omylem načtený textový sloupec nebo nečekané jednotky. Argument `n = 10` říká, že chceme zobrazit **prvních deset hodnot**; jiné číslo za `n` = by změnilo počet zobrazených hodnot. Ani jedna kontrola ale ještě neukazuje tvar celého souboru hodnot.

Doplňující: integer a double jako dva způsoby uložení čísel

R ukládá 5L jako celé číslo typu `integer` a 5 jako číslo typu `double`:

```
typeof(5L) # "integer"
typeof(5)  # "double"
```

Jde o **technický způsob uložení čísla v počítači**, nikoli automaticky o statistický typ proměnné. Zaokrouhlená tělesná hmotnost 70 může být spojitě měření uložené jako `double`; počet pěti mláďat může být diskrétní proměnná uložená jako `integer`. O statistickém typu rozhoduje význam hodnot.

5.4 Jak vypadá celý datový rámec?

Vektor drží jednu proměnnou. Původní datový rámec drží více proměnných vedle sebe. Každý řádek stále představuje jeden druh.

```
# Počet řádků a sloupců původních dat.
dim(ggplot2::msleep)
```

```
[1] 83 11
```

```
# Prvních šest řádků původních dat.
head(ggplot2::msleep, n = 6)
```

```
# A tibble: 6 × 11
  name      genus vore order conservation sleep_total sleep_rem sleep_cycle awake
<chr>    <chr> <chr> <chr> <chr>          <dbl>     <dbl>     <dbl> <dbl>
1 Cheetah Acin... carni Carn... lc           12.1      NA      NA      11.9
2 Owl mo... Aotus omni Prim... <NA>         17        1.8    NA       7
3 Mounta... Aplo... herbi Rode... nt          14.4      2.4    NA      9.6
4 Greate... Blar... omni Sori... lc          14.9      2.3    0.133   9.1
5 Cow      Bos   herbi Arti... domesticated 4         0.7    0.667   20
```

```
6 Three-... Brad... herbi Pilo... <NA>          14.4      2.2      0.767    9.6
# i 2 more variables: brainwt <dbl>, bodywt <dbl>
```

Otázka	Odpověď pro <code>msleep</code>
Co představuje jeden řádek?	jeden zastoupený druh savce
Co představuje sloupec <code>sleep_total</code> ?	celkovou dobu spánku za den v hodinách
Co představuje sloupec <code>bodywt</code> ?	tělesnou hmotnost druhu v kilogramech
Je jeden řádek jeden jedinec?	ne; druh je zde shrnut jednou hodnotou

Druh není jedinec

Řádek reprezentuje hodnotu vybranou pro **druh**. Slon africký a drobný rejsek mají v tabulce každý právě jeden řádek. Výsledek proto popisuje zastoupené druhy, nikoli četnost nebo hmotnost všech savčích jedinců na Zemi.

Doplňující: odkud data pocházejí a co v nich chybí

Dataset `msleep` má podle [dokumentace balíčku ggplot2](#) 83 řádků a 11 proměnných. Údaje o spánku a hmotnosti vycházejí z práce Savage a West (2007), [A quantitative, theoretical framework for understanding mammalian sleep](#). Dokumentace uvádí, že taxonomický řád, stav ochrany a typ potravy byly doplněny z Wikipedie.

Ne všechny buňky jsou vyplněné: v celé tabulce chybí 136 hodnot. Celková doba spánku a tělesná hmotnost jsou úplné, ale například stav ochrany chybí u 29 druhů a typ potravy u 7 druhů. Chybějící hodnota není nula; znamená, že údaj v tabulce nemáme.

Doplňující: výběr není celá populace

Výběr je soubor pozorování, která máme skutečně k dispozici. Cílová populace je širší celek, o kterém bychom chtěli něco říct. Dataset `msleep` obsahuje zastoupené druhy savců, ale není automaticky náhodným průřezem všech savců ani všech jedinců. Průměr, medián nebo SD proto nejprve přesně popisují tento soubor; možnost zobecnění závisí také na tom, jak byly druhy vybrány a jak vznikly jejich souhrnné hodnoty.

Dvě tabulky mohou mít stejný počet řádků a stejně přesně vypočtené statistiky, ale různou vypovídací hodnotu. Pokud v jedné chybí například málo prozkoumané noční druhy, samotný výpočet tuto nerovnováhu neopraví. V lekci o nejistotě se vrátíme k odhadu z jednoho výběru; později budeme řešit také situace, kdy řádky nepředstavují nezávislé informační jednotky.

6 Vizualizace dat: nejdříve se podívejte

Samotný výpis 83 hodnot se čte obtížně. Graf uspořádá hodnoty podle jejich velikosti a dovolí nám vidět rozdělení: kde se hodnoty hromadí, jak široce jsou rozptýlené a zda některé leží stranou.

6.1 Proč začínáme grafem?

Než začneme počítat souhrnná čísla, je dobrým obecným pravidlem **nejdříve zobrazit jednotlivé hodnoty**. Graf může odhalit shluky, mezery, asymetrii nebo hodnoty daleko od ostatních. Teprve potom dokážeme posoudit, který číselný popis bude pro daná data smysluplný.

Nikdy nepracujte jen s čísly bez grafu

Samotný výpis hodnot se čte obtížně a souhrnné číslo část informace vždy skryje. **Graf není ozdoba výsledku. Je to první kontrola toho, co se číselný popis chystá zjednodušit.**


6.2 Bodový graf

Bodový graf (anglicky *dot plot*; zde uspořádaný jako *beeswarm plot*) zobrazuje každou hodnotu jako samostatný bod. Body jsou mírně posunuté nahoru a dolů, aby se nepřekrývaly a lépe využily plochu grafu.

Kolik druhů představuje jeden bod? Kde leží nejkratší a nejdelší doba spánku?

6.2.a Graf

Každý bod představuje jeden zastoupený druh




6.2.b Kód v R

```
# Zobrazíme každou hodnotu jako jeden bod.
stripchart(
  x = vec_spanek_h,
  method = "jitter",
  jitter = 0.25,
  pch = 19,
  cex = 1.2,
  col = "#6B7280",
  xlab = "Celkový spánek za den (h)",
```

```
main = "Bodový graf"  
)
```

Bodový graf




Výhoda bodového grafu je úplnost: žádná hodnota nezmizí. Nevýhodou je, že u velkých datových souborů se může mnoho bodů překrývat.

6.3 Hodnoty seskupené do intervalů

Histogram seskupuje číselné hodnoty do navazujících intervalů neboli **košů** (anglicky *bins*). Výška sloupce ukazuje četnost hodnot v daném koši.


Které rozmezí spánku obsahuje nejvíce druhů? Co už z histogramu nedokážete vyčíst o jednotlivém druhu?

6.3.a Graf




6.3.b Kód v R

```
# Rozdělíme osu na intervaly široké dvě hodiny.  
hist(  
  x = vec_spanek_h,  
  breaks = seq(  
    from = 0,  
    to = 22,  
    by = 2  
  ),  
  col = "#D8C9E8",  
  border = "white",  
  xlab = "Celkový spánek za den (h)",  
  ylab = "Počet druhů",  
  main = "Histogram doby spánku"  
)
```



Doplňující: jak volit šířku koše?

Volba šířky koše (anglicky *bin width*) mění míru detailu, ale nemění původní hodnoty. Příliš úzké koše vytvoří zubatý graf; příliš široké koše mohou skrýt důležitý tvar.




6.4 Graf hustoty

Graf hustoty (anglicky *density plot*) je vyhlazený pohled na tvar číselných hodnot. Neukazuje počty druhů; osa y vyjadřuje hustotu. Křivka je proto vhodná pro porovnávání tvaru, ale méně vhodná pro čtení konkrétních četností.

Kde má křivka vrchol? Odpovídá tato oblast nejvyšším sloupcům histogramu?


6.4.a Graf



6.4.b Kód v R

```
# Odhadneme vyhlazenou hustotu hodnot.
hustota_spanku <-
  density(
    x = vec_spanek_h
  )

plot(
  x = hustota_spanku,
  xlab = "Celkový spánek za den (h)",
  ylab = "Hustota",
  main = "Graf hustoty doby spánku"
)
```



6.5 Tři pohledy na tutéž proměnnou

Graf	Co zachovává	Co skrývá nebo mění
Bodový graf (<i>dot/beeswarm plot</i>)	každou jednotlivou hodnotu	při velkém počtu hodnot může být přeplněný
Histogram (<i>histogram</i>)	četnosti v intervalech a celkový tvar	přesné hodnoty; vzhled závisí na šířce koše
Graf hustoty (<i>density plot</i>)	hladký tvar rozdělení	konkrétní počty a jednotlivé hodnoty

Žádný z těchto grafů není automaticky nejlepší. Vybíráme podle otázky a podle toho, co potřebujeme čtenáři ukázat.

7 Deskriptivní statistiky: čísla, která patří ke grafu

Graf ukazuje celý tvar dat. Někdy ale potřebujeme také několik **srovnatelných čísel**: například do tabulky výsledků nebo do jedné věty v článku. **Deskriptivní statistiky** shrnou:

- **polohu** hodnot: kde leží jejich střed nebo okraje;
- **variabilitu**: jak moc se hodnoty liší.

Souhrnné číslo nikdy nenahrazuje graf. Čteme je společně.

7.1 Malý skutečný příklad

Pro ruční výpočty použijeme devět známých druhů z `msleep`. Každý řádek stále představuje druh a hodnotou je celkový spánek za den v hodinách.

Druh	Původní název (name)	Spánek za den (h)
kůň	Horse	2.9
ovce	Sheep	3.8
kráva	Cow	4.0
člověk	Human	8.0
králík	Rabbit	8.4
prase	Pig	9.1
šimpanz	Chimpanzee	9.7
pes	Dog	10.1
kočka domácí	Domestic cat	12.5

Hodnoty jsou v tabulce seřazené od nejmenší po největší. Díky tomu můžeme sledovat, odkud se každé další číslo bere.

7.2 Minimum a maximum

Minimum je nejmenší pozorovaná hodnota a **maximum** největší. V malém příkladu je minimum 2.9 h a maximum 12.5 h.

```
# Nejkratší pozorovaná doba spánku.  
min(vec_maly_spanek)
```

```
[1] 2.9
```


```
# Nejdelší pozorovaná doba spánku.  
max(vec_maly_spanek)
```

[1] 12.5

Na grafu jsou to levý a pravý okraj pozorovaných hodnot.


7.2.a Minimum

Minimum = 1,9 h



7.2.b Maximum

Maximum = 19,9 h



Minimum a maximum popisují pozorovaný rozsah, ale silně závisí na jediném nejkrajnějším řádku.

7.3 Aritmetický průměr

Aritmetický průměr (anglicky *mean*) získáme tak, že sečteme všechny hodnoty a součet vydělíme jejich počtem.

Nejdříve slovy:

$$\text{průměrná doba spánku} = \frac{\text{součet dob spánku}}{\text{počet druhů}}$$

V malém příkladu dosadíme všechny hodnoty z tabulky:

$$\begin{aligned}\text{průměrná doba spánku} &= \frac{2,9 + 3,8 + 4 + 8 + 8,4 + 9,1 + 9,7 + 10,1 + 12,5}{9} \\ &= \frac{68,5}{9} \\ &= 7,61 \text{ h}\end{aligned}$$

Obecný zápis je:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Zde:

- x_i je hodnota i -tého pozorování;
- n je počet pozorování;
- $\sum$ znamená součet všech hodnot;
- $\bar{x}$ je průměr.

```
# Průhledný výpočet: součet dělený počtem.  
sum(vec_maly_spanek) / length(vec_maly_spanek)
```


```
[1] 7.611111
```

```
# Stejný výsledek jednou funkcí.  
mean(vec_maly_spanek)
```

```
[1] 7.611111
```

Průměr = 10,43 h

Přerušovaná čára označuje aritmetický průměr



Každá hodnota aritmetický průměr ovlivňuje. Proto se průměr posouvá směrem k velmi vzdáleným hodnotám.

7.4 Prostřední hodnota seřazených dat

Medián (anglicky *median*) je prostřední hodnota seřazených dat. Polovina hodnot leží nejvýše na jeho úrovni a polovina nejméně na jeho úrovni.

Nejdříve vztah zapíšeme pouze slovy:

medián doby spánku = prostřední hodnota seřazených dob spánku

V malém příkladu máme lichý počet hodnot. Prostřední je pátá:

2, 9, 3, 8, 4, 8, 8, 4, 9, 1, 9, 7, 10, 1, 12, 5

Teprve nyní zápis zobecníme. Pro lichý počet n je medián hodnotou na pozici:

$$\tilde{x} = x_{(\frac{n+1}{2})}$$

Zde:


- x označuje sledovanou číselnou proměnnou;
- $x_{(i)}$ označuje i -tou hodnotu po seřazení;
- n je počet hodnot;
- $\tilde{x}$ je medián.

```
median(vec_maly_spanek)
```

```
[1] 8.4
```

Medián = 10,1 h

Čára rozděljuje seřazené druhy na dvě poloviny




7.5 Průměr a medián: návrat k titulku

Nyní máme oba nástroje, které vytvořily úvodní titulky. Podívejme se na hmotnosti všech zastoupených druhů.

7.5.a Původní osa

Několik velmi těžkých druhů roztahuje osu


Oranžově průměr, fialově medián



7.5.b Přiblížení pomocí logaritmické osy

Logaritmická osa zpřístupní lehké i těžké druhy

Výpočty zůstávají v původních kilogramech



Na původní ose vidíme, že většina druhů leží blízko nuly ve srovnání s několika velmi těžkými druhy. Logaritmická osa pouze mění rozestupy na grafu, aby byly body čitelné; průměr i medián jsou stále vypočtené z kilogramů.

- Průměr hmotnosti je **166 kg**.
- Medián hmotnosti je **1,67 kg**.

Obě čísla jsou vypočtena správně. Průměr ale silně posunulo několik velmi těžkých druhů. Medián lépe popisuje prostřední řádek této výrazně asymetrické tabulky.

Vyřešení úvodního hlasování

Nejpřesnější odpověď byla C) **Obě čísla mohou být vypočtena správně.** Správný výpočet však ještě nezaručuje poctivý titul. Musíme také uvést, jaké shrnutí jsme použili, jak vypadá graf a co představuje jeden řádek.

Doplňující: kdy může být průměr užitečnější?

Průměr je přirozený pro přibližně symetrická číselná data bez mimořádně vzdálených hodnot a je základním stavebním kamenem mnoha statistických modelů. Medián je odolnější vůči odlehlým pozorováním a často lépe popisuje střed silně asymetrických dat. Volba není soutěž mezi „dobrou“ a „špatnou“ statistikou; musí odpovídat grafu a otázce.

7.6 Percentily a kvartily

Percentil (anglicky *percentile*) je hodnota, pod níž leží určitý podíl seřazených dat. Několik percentilů má vlastní názvy; kvartily dělí seřazená data na čtyři části:

- 0. percentil je minimum;
- 25. percentil je dolní kvartil Q1;
- 50. percentil je medián;
- 75. percentil je horní kvartil Q3;
- 100. percentil je maximum.


```
quantile(  
  x = vec_maly_spanek,  
  probs = c(0, 0.25, 0.50, 0.75, 1)  
)
```

0%	25%	50%	75%	100%
2.9	4.0	8.4	9.7	12.5

Najděte v následujícím grafu prostřední čáru a pásmo mezi Q1 a Q3. Kolik hodnot by přibližně mělo ležet uvnitř pásma?

Q1, medián a Q3 rozdělují seřazené hodnoty

Stínované pásmo obsahuje prostřední polovinu druhů



Doplňující: proč kvartil nemusí být přímo v datech?

U malého souboru může požadovaná procentní pozice ležet mezi dvěma pozorovanými hodnotami. R pak podle zvolené metody provede interpolaci. Proto kvartil nemusí být přesně

jednou z hodnot v tabulce. Funkce `quantile()` nabízí více metod pomocí argumentu `type`; pro tento úvod ponecháváme výchozí nastavení.

7.7 Prostřední polovina hodnot

Medián popisuje polohu středu, nikoli šířku dat. Mezikvartilové rozpětí (IQR) (anglicky *interquartile range*) je vzdálenost mezi horním a dolním kvantilem.

Nejdříve slovy:

mezikvartilové rozpětí doby spánku = horní kvartil doby spánku – dolní kvartil doby spánku

V malém příkladu nejprve znovu ukážeme všech devět seřazených hodnot. Dolní a horní kvartil jsou zde třetí a sedmá hodnota:

$$2, 9, 3, 8, \boxed{4,0}_{Q_1}, 8, 8, 4, 9, 1, \boxed{9,7}_{Q_3}, 10, 1, 12, 5$$

Teprve potom odečteme jejich hodnoty:

$$\begin{aligned} \text{IQR} &= 9,7 - 4,0 \\ &= 5,7 \text{ h} \end{aligned}$$

Obecný zápis je:

$$\text{IQR} = Q_3 - Q_1$$

Zde Q_1 označuje dolní kvartil a Q_3 horní kvartil. IQR popisuje rozsah střední poloviny hodnot.

```
quantile(  
  x = vec_maly_spanek,  
  probs = c(0.25, 0.75)  
)
```


```
25% 75%  
4.0 9.7
```

```
IQR(vec_maly_spanek)
```

```
[1] 5.7
```

IQR = 5,9 h

Stínované pásmo = prostřední polovina druhů



7.8 Od středu k variabilitě

Nyní známe minimum, maximum, průměr, medián, kvartily a IQR. Následující dva malé soubory jsou **záměrně sestavené didaktické příklady**, nikoli další pozorování z `msleep`. Jejich průměr je stejný:

```
vec_spanek_a <-  
  c(8, 9, 9, 10, 10, 10, 11, 11, 12)
```

```
vec_spanek_b <-  
  c(6, 6, 8, 8, 10, 12, 12, 14, 14)
```

```
mean(vec_spanek_a)
```

```
[1] 10
```


```
mean(vec_spanek_b)
```

```
[1] 10
```

Nejdříve graf sami popište: kde leží hodnoty a v čem se oba soubory liší?

Stejný průměr, jiný tvar hodnot

Přerušená čára označuje průměr 10 hodin



Soubor A je soustředěný kolem 10 hodin. Soubor B má více hodnot na obou okrajích a méně hodnot poblíž středu. Stejný průměr tuto odlišnost skryl.

Potřebujeme ještě jedno číslo

Jak bychom jedním číslem popsali vzdálenosti **všech hodnot od průměru**? Odpověď budeme hledat v následující části.


7.9 Jak daleko hodnoty leží od středu

Průměr popsal střed. Nyní potřebujeme říci, jak moc jsou hodnoty **rozptýlené kolem průměru**. Začneme vzdáleností každé hodnoty od průměru.

Nejdříve slovy:

$\text{odchylka doby spánku druhu} = \text{doba spánku druhu} - \text{průměrná doba spánku}$

Na grafu je odchylka vidět jako úsek od průměru k hodnotě každého druhu. Fialové úseky vedou pod průměr, oranžové nad něj.



Extra: od odchylek k součtu čtverců, rozptylu a SD

Tabulka propojuje každou hodnotu s jejím místem v dalším výpočtu:

Druh	Spánek (h)	Odchylka od průměru (h)	Čtverec odchylky (h ²)
kůň	2.9	-4.71	22.19
ovce	3.8	-3.81	14.52
kráva	4.0	-3.61	13.04
člověk	8.0	0.39	0.15
králík	8.4	0.79	0.62
prase	9.1	1.49	2.22
šimpanz	9.7	2.09	4.36
pes	10.1	2.49	6.19
kočka domácí	12.5	4.89	23.90


Například u kočky domácí dosadíme hodnotu z grafu a průměr:

$$\begin{aligned} \text{odchylka spánku kočky domácí} &= 12,5 - 7,61 \\ &= 4,89 \text{ h} \end{aligned}$$

Obecný zápis odchylky je:

$$e_i = x_i - \bar{x}$$

Zde e_i označuje odchylku i -té hodnoty od průměru. Kladné a záporné odchylky se při prostém součtu vyruší: zde dávají po zaokrouhlení 0,00 h. Proto je umocníme na druhou a sečteme. Výsledek se nazývá **součet čtverců** (anglicky *sum of squares*, SS).



V tomto souboru přispívá k součtu čtverců nejvíce **kočka domácí**: její čtverec odchylky je 23,90 h². Nejde o chybu; kočka jen leží ze všech devíti druhů nejdále od průměru.

$$\begin{aligned} \text{součet čtverců odchylek} &= 22,19 + 14,52 + 13,04 + 0,15 + 0,62 + 2,22 + 4,36 + 6,19 + 23,90 \\ &= 87,21 \text{ h}^2 \end{aligned}$$

Obecně:

$$SS = \sum_{i=1}^n (x_i - \bar{x})^2$$

Výběrový rozptyl (anglicky *sample variance*) získáme vydělením součtu čtverců počtem hodnot minus jedna. Když máme jedinou hodnotu, její průměr je ona sama a odchylka je vždy nula: o skutečné proměnlivosti tak nic nezjistíme. U dvou hodnot po určení průměru stačí znát jednu odchylku, protože druhá musí být opačná. Po odhadu průměru tedy zbývá o jednu nezávislou odchylku méně; tím si vysvětlíme dělitele $n - 1$ bez formální definice stupňů volnosti.

Nejdříve slovy:

$$\text{výběrový rozptyl doby spánku} = \frac{\text{součet čtverců odchylek}}{\text{počet druhů} - 1}$$

V malém příkladu:

$$\begin{aligned}\text{výběrový rozptyl doby spánku} &= \frac{87,21}{9-1} \\ &= \frac{87,21}{8} \\ &= 10,90 \text{ h}^2\end{aligned}$$

Obecně:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Rozptyl má čtvercové jednotky, zde hodiny na druhou. Abychom se vrátili k hodinám, vezmeme odmocninu. Tím získáme směrodatnou odchylku (SD) (anglicky *standard deviation*).

Nejdříve slovy:

$$\text{směrodatná odchylka doby spánku} = \sqrt{\text{výběrový rozptyl doby spánku}}$$

V malém příkladu:

$$\begin{aligned}\text{směrodatná odchylka doby spánku} &= \sqrt{10,90} \\ &= 3,30 \text{ h}\end{aligned}$$

Obecně:

$$s = \sqrt{s^2}$$

Zde s^2 označuje výběrový rozptyl a s směrodatnou odchylku. SD má stejné jednotky jako původní proměnná.

```
# Výběrový rozptyl v hodinách na druhou.  
var(vec_maly_spanek)
```

```
[1] 10.90111
```

```
# Směrodatná odchylka v hodinách.  
sd(vec_maly_spanek)
```

```
[1] 3.301683
```

Směrodatná odchylka (SD) vyjadřuje, jak rozptýlené jsou hodnoty kolem průměru, ve stejných jednotkách jako původní měření. Pro doby spánku ji spočítáme v R pomocí `sd(vec_maly_spanek)`. Podrobný výpočet přes součet čtverců a rozptyl je v rámečku Extra.

Doplňující: SD není standardní chyba

SD popisuje, jak se od sebe liší **pozorované hodnoty** — zde doby spánku jednotlivých zastoupených druhů. Standardní chyba (SE) bude později popisovat něco jiného: jak přesný je **odhad**, například odhad průměru nebo sklonu modelu.


Velká SD tedy neznamena automaticky chybný výpočet a malá SD neznamena automaticky přesný odhad pro celou populaci. Zatím stačí držet dvě otázky odděleně: **jak rozdílná jsou pozorování?** odpovídá SD; **jak přesný je náš odhad?** začne odpovídat SE v lekci o nejistotě odhadu.

7.10 SD jako vzdálenost na grafu

Na grafu můžeme kolem průměru vyznačit vzdálenost jedné SD na obě strany. Pásmo není automatickým pravidlem, kolik bodů „musí“ obsahovat. Ukazuje měřítko rozptýlení hodnot kolem průměru.

Průměr = 10,43 h; SD = 4,45 h


Stínované pásmo sahá jednu SD na každou stranu od průměru



7.11 Stejná průměrná mzda, jiná SD

Význam SD si lze snadno představit u měsíčních mezd. Následující dvě firmy jsou **smyšlený příklad**: v obou je průměrná mzda 50 tisíc Kč, ale jednotlivé mzdy se kolem stejného průměru rozkládají jinak.

Stejný průměr 50 tisíc Kč, jiná šířka histogramu



Ve firmě A leží mzdy blíže průměru a SD je 3 tisíce Kč. Ve firmě B jsou mzdy rozptýlenější a SD je 12 tisíc Kč. **Vyšší SD znamená větší typickou vzdálenost hodnot od průměru**, nikoli automaticky vyšší nebo nižší mzdu.

Doplňující: co může míra rozptýlení znamenat biologicky?

Představte si dvě populace ptáků se stejnou průměrnou délkou křídla. Jedna má malou SD, druhá velkou. První je z hlediska délky křídel uniformnější; druhá variabilnější. Příčinou mohou být například rozdílné podmínky prostředí, smíšené věkové skupiny, pohlavní dimorfismus nebo chyba měření. SD sama příčinu neodhalí, ale upozorní, že biologická variabilita stojí za další otázku.

7.12 Které dvojice souhrnů patří k sobě?

Míra středu	Míra variability	Kdy je dvojice často užitečná
průměr (<i>mean</i>)	směrodatná odchylka (<i>standard deviation</i>)	přibližně symetrická číselná data bez výrazně vzdálených hodnot
medián (<i>median</i>)	IQR (<i>interquartile range</i>)	asymetrická číselná data nebo data s výrazně vzdálenými hodnotami

Nejde o mechanické pravidlo. Nejprve vždy prohlédněte graf a zvažte biologický význam.

8 Statistiky jako vizualizace: stavíme graf ze souhrnů


Minimum, kvartily, medián a IQR již známe. Nyní z nich sestavíme krabíkový graf (boxplot) krok za krokem, aby žádná jeho část nebyla záhadným symbolem. Pokračujeme s tělesnou hmotností:

správně vypočtený titulek tak můžeme doplnit grafem, který ukáže celé rozdělení zastoupených druhů.

8.1 Krok 1: jednotlivé hodnoty a medián

Začneme bodovým grafem a přidáme čáru na pozici mediánu. Každý bod stále vidíme.

Krok 1: medián rozděluje seřazené hodnoty na poloviny




8.2 Krok 2: krabice je IQR

Obdélník od Q1 do Q3 obsahuje prostřední polovinu hodnot. Jeho šířka je IQR.

Krok 2: krabice sahá od Q1 do Q3


Její šířka odpovídá IQR



8.3 Krok 3: vousy a body za nimi

Od hran krabice odměříme vzdálenost 1,5násobku IQR. Vous končí na nejkrajnější skutečně pozorované hodnotě, která ještě leží uvnitř této hranice. Hodnoty za vousy se vykreslí samostatně jako možná odlehlá pozorování. V předchozích krocích byly všechny původní body šedé; od tohoto kroku zobrazujeme body za hranicemi samostatně šedě. Chceme je vidět, ale nejsou automaticky hlavním sdělením grafu.

Krok 3: přidáme vousy a samostatné body za nimi



Doplňující: jak určíme bod za vousy?

Nejdříve pravidlo zapíšeme slovy:

$$\text{dolní hranice} = \text{dolní kvartil} - 1,5 \times \text{IQR}$$

$$\text{horní hranice} = \text{horní kvartil} + 1,5 \times \text{IQR}$$

Pro tělesnou hmotnost dosadíme hodnoty z našeho souboru:

$$\begin{aligned}\text{dolní hranice} &= 0,174 - 1,5 \times 41,58 \\ &= -62,19 \text{ kg}\end{aligned}$$

$$\begin{aligned}\text{horní hranice} &= 41,75 + 1,5 \times 41,58 \\ &= 104,1 \text{ kg}\end{aligned}$$

Obecně:

$$L = Q_1 - 1,5 \times \text{IQR}$$

$$U = Q_3 + 1,5 \times \text{IQR}$$

Zde L označuje dolní hranici, U horní hranici, Q_1 dolní kvartil a Q_3 horní kvartil. Bod menší než L nebo větší než U se vykreslí samostatně. Vous nekončí přímo na vypočtené hranici, ale na nejkrajnější **skutečně pozorované hodnotě**, která ještě leží uvnitř hranice.

Bod za vousy není automaticky chyba

Pravidlo $1,5 \times \text{IQR}$ označuje hodnotu k bližšímu prozkoumání. Bod může být překlep, zvláštní měření nebo zcela reálný biologický druh. O jeho významu rozhodujeme podle zdroje dat a biologického kontextu, ne podle grafu samotného.


Ve všech následujících krabicových grafech označujeme jako možné odlehlé hodnoty **stejně druhy podle hranic vypočtených v původních kilogramech**. Logaritmická osa mění pouze rozestupy mezi body, nikoli pravidlo pro jejich označení.

8.4 Výsledný krabicový graf

R sestaví stejné prvky jedním příkazem.

8.4.a Graf


Krabicový graf tělesné hmotnosti



8.4.b Kód v R

```
# Vytvoříme vodorovný krabicový graf.  
boxplot(  
  x = vec_hmotnost_kg,  
  horizontal = TRUE,  
  log = "x",  
  col = "#D8C9E8",  
  outpch = 21,  
  outcol = "#6B7280",  
  outbg = "#6B7280",  
  xlab = "Tělesná hmotnost (kg; logaritmická osa)",  
  main = "Krabicový graf tělesné hmotnosti"  
)
```

Krabicový graf tělesné hmotnosti



Prvek	Co znamená
čára uvnitř krabice	medián, tedy 50. percentil
levý a pravý okraj krabice	Q1 a Q3
šířka krabice	IQR, tedy prostřední polovina hodnot
vousy	nejkrajnější hodnoty uvnitř hranice $1,5 \times \text{IQR}$
samostatné body	možné odlehlé hodnoty za vousy

8.5 Když chceme vidět tvar: houslový graf

Houslový graf (anglicky *violin plot*) zachovává hladký obrys rozdělení: čím je „housle“ v určité části širší, tím více hodnot se v této oblasti soustředí.


Krabicový graf rychle ukáže medián, kvartily a možné odlehlé hodnoty, ale neukáže, zda se hodnoty hromadí v jednom nebo několika shlucích. V takové situaci může být houslový graf informativnější. Úzký boxplot uvnitř ponechává známé souhrny a obrys kolem něj doplňuje tvar dat.

Obecný základní zápis může vypadat takto:

```
# Jedna housle zobrazí rozdělení hodnot v každé skupině.
ggplot2::ggplot(
  data = data_mereni,
  mapping = ggplot2::aes(
    x = skupina,
    y = hodnota
  )
) +
  ggplot2::geom_violin()
```

Názvy `data_mereni`, `skupina` a `hodnota` nahradíme názvy z vlastních dat.

Kde je housle nejširší? Dokázali byste tuto informaci vyčíst ze samotného krabicového grafu? Jak daleko od sebe leží průměr a medián?



Obrázek 1: Oranžová svislá čára označuje aritmetický průměr, čára uvnitř krabice medián a šedé body možné odlehlé hodnoty.

Doplňující: úplný kód kombinovaného grafu

Tento kód navazuje na výpočet kvartilů, vousů, možných odlehlých hodnot a průměru v předchozí části.

```
# Přidáme ke tvaru rozdělení krabici, body za vousy a průměr.
ggplot2::ggplot(
  data = data_hmotnost,
  mapping = ggplot2::aes(x = hmotnost_kg, y = "")
) +
  ggplot2::geom_violin(
    orientation = "y", trim = FALSE,
    fill = "#D8C9E8", color = "#6B7280"
  ) +
  ggplot2::geom_boxplot(
    data = data_boxplot_hmotnost,
    mapping = ggplot2::aes(
      y = skupina,
      xmin = vous_dolni, xlower = q1, xmiddle = median,
      xupper = q3, xmax = vous_horni
    ),
    stat = "identity", orientation = "y", width = 0.14,
    fill = "white", inherit.aes = FALSE
  ) +
  ggplot2::geom_point(
    data = data_odlehle_hmotnost,
    mapping = ggplot2::aes(x = hmotnost_kg, y = ""),
    inherit.aes = FALSE, shape = 21,
    color = "#6B7280", fill = "#6B7280", size = 2.4
  ) +
  ggplot2::geom_vline(
    xintercept = prumer_hmotnost,
    color = "#F3A712", linewidth = 1.3
  ) +
  ggplot2::scale_x_log10() +
  ggplot2::labs(
    x = "Tělesná hmotnost (kg; logaritmická osa)",
    y = NULL
  )
```

Průměr přidáváme pouze do kombinovaného grafu, abychom vedle tvaru rozdělení viděli oba způsoby popisu středu. Houslový graf ale také vyhlazuje data. U malého souboru proto mohou být poctivější jednotlivé body; žádný typ grafu není nejlepší ve všech situacích.

Doplňující: co tento souhrnný graf skrývá?

Krabicový graf je kompaktní a dobře se skládá vedle dalších skupin, ale skrývá jednotlivé hodnoty i podrobný tvar rozdělení. Dva různé soubory mohou mít stejný boxplot. Když je to možné, doplňte jej body, houslovým grafem nebo se vraťte k histogramu.

9 Typy proměnných: zobecnění na konci

Doteď jsme sledovali hlavně jednu proměnnou: dobu spánku savce za den. Teprve teď máme dost zkušeností, abychom si položili obecnější otázku: **jaký druh informace proměnná nese?**

U jednoho savce bychom mohli zaznamenat například:

- dobu spánku v hodinách;
- hmotnost v kilogramech;
- počet pozorovaných jedinců;
- typ potravy;
- velikostní kategorii.

Tyto údaje nelze popisovat ani zobrazovat všechny stejným způsobem. Stejně zapsané číslo totiž může znamenat něco úplně jiného:

Nejprve proto určujeme pozorovací jednotku: koho nebo co jeden řádek reprezentuje.

Zápis	Co znamená	Typ proměnné
37,0	tělesná teplota 37,0 °C	numerická spojitá
37	počet rostlin na ploše	numerická diskrétní
37	číselný kód lokality	kategoriální nominální
3	hodnocení na škále 1–5	kategoriální ordinální

Typ proměnné neurčuje vzhled hodnoty

O typu proměnné rozhoduje **význam hodnot a způsob jejich vzniku**, ne to, zda jsou v tabulce zapsány číslem nebo slovem.

Statistický typ není totéž co třída objektu v R

R popisuje technickou podobu objektu pomocí `class()` a `typeof()`. Funkce `str()` ukáže jeho stručnou strukturu a několik hodnot. Tyto kontroly jsou velmi užitečné, ale samy nerozhodnou, zda je proměnná spojitá, diskrétní, nominální nebo ordinální. K tomu stále potřebujeme vědět, co hodnoty znamenají a jak vznikly.

Při určování typu si zkuste doplnit větu:

Jeden řádek představuje ____ a tato proměnná říká ____.

Tím se zároveň vracíte k pozorovací jednotce. Počet druhů v jednom řádu může být například vlastností lokality, zatímco řád savce je vlastností druhu.

9.1 Numerická spojitá proměnná

Numerická spojitá proměnná (*continuous numerical variable*; vyhledávací termín *continuous data*) vzniká měřením. Mezi dvěma hodnotami si obvykle umíme představit další možné hodnoty, i když je přístroj zaokrouhlí.

Příklady z reálného světa:

- délka těla nebo listu,
- tělesná hmotnost,
- teplota,
- koncentrace látky,
- doba spánku.

Jak ji uvidíme v R?

```
# Vybereme sloupec s naměřenou dobou spánku.  
vec_spanek_h <- ggplot2::msleep[["sleep_total"]]  
  
# Zobrazíme prvních šest hodnot.  
head(vec_spanek_h)
```

```
[1] 12.1 17.0 14.4 14.9  4.0 14.4
```

```
# Zjistíme třídu objektu, jak ji popisuje R.  
class(vec_spanek_h)
```

```
[1] "numeric"
```

```
# Zjistíme, jak jsou hodnoty technicky uloženy.  
typeof(vec_spanek_h)
```

```
[1] "double"
```

```
# Získáme stručný přehled o struktuře objektu.  
str(vec_spanek_h)
```


```
num [1:83] 12.1 17 14.4 14.9 4 14.4 8.7 7 10.1 3 ...
```

R tento vektor zobrazí jako `numeric` a technicky jej uloží jako `double`. Z toho ještě nepozná, že jde o spojitou proměnnou. To usuzujeme z významu: doba spánku vznikla měřením a mezi dvěma hodnotami si umíme představit další.

Pro spojitou proměnnou jsme už použili čtyři vhodné grafy: bodový graf, histogram, graf hustoty a krabicový graf.

9.1.a Bodový graf


Ukazuje každé pozorování. Je výborný pro malý až střední soubor.



Obrázek 2: Každá tečka představuje jeden druh savce.

9.1.b Histogram


Sdružuje hodnoty do intervalů. Hodí se, když chceme vidět tvar rozdělení.



Obrázek 3: Histogram spojité proměnné; vzhled závisí na šířce košů.

9.1.c Graf hustoty


Nabízí vyhlazený pohled na tvar rozdělení. Vyhlazení je analytické rozhodnutí, nikoli další měření.



Obrázek 4: Vyhlazený odhad hustoty spojitě proměnné.

9.1.d Krabicový graf

Zhušťuje data do mediánu, kvartilů, vousů a případných odlehlých pozorování.



Obrázek 5: Krabicový graf stejné spojitě proměnné.

9.2 Numerická diskrétní proměnná

Numerická diskrétní proměnná (*discrete numerical variable*, také *count data*) vzniká nejčastěji počítáním. Možné hodnoty jsou oddělené: mezi 4 a 5 mláďaty není 4,6 mláděte.

Příklady:

- počet mláďat,
- počet druhů na lokalitě,
- počet semen,
- počet návštěv květu,

- počet přečtených sekvencí.

Oba počty jsou diskrétní, ale při volbě grafu a souhrnu záleží také na rozsahu možných hodnot a biologické otázce: počet mláďat mívá jen několik hodnot, zatímco počet listů na stromě může být velmi vysoký. Samotný štítek „diskrétní“ nám proto neurčí jeden univerzální graf.

V našem datasetu můžeme změnit pozorovací jednotku a spočítat, kolik druhů zastupuje každý taxonomický řád:

Jak ji uvidíme v R?

```
# Spočítáme druhy v každém taxonomickém řádu.
cetnosti_radu <- table(ggplot2::msleep[["order"]])

# Ponecháme jen vypočtené počty bez názvů řádů.
vec_pocet_druhu <- as.integer(cetnosti_radu)

# Zobrazíme prvních šest počtů.
head(vec_pocet_druhu)
```

```
[1] 1 6 12 3 2 2
```

```
# Zjistíme třídu objektu, jak ji popisuje R.
class(vec_pocet_druhu)
```

```
[1] "integer"
```

```
# Zjistíme, jak jsou hodnoty technicky uloženy.
typeof(vec_pocet_druhu)
```

```
[1] "integer"
```


```
# Získáme stručný přehled o struktuře objektu.
str(vec_pocet_druhu)
```

```
int [1:19] 1 6 12 3 2 2 2 2 2 3 ...
```

R vrátí třídu i způsob uložení `integer`, protože jsme vytvořili vektor celých počtů. Ani `integer` ale automaticky neznamená diskrétní proměnnou: například zaokrouhlená teplota může být také zapsána celým číslem. Rozhodující je, že zde druhy skutečně počítáme.


Takovou četnost můžeme zobrazit jako body nebo sloupcový graf.

9.2.a Bodový graf četností



Obrázek 6: Počet druhů savců zastoupených v jednotlivých taxonomických řádech.

9.2.b Sloupcový graf



Obrázek 7: Sloupcový graf týchž počtů.

U diskrétních dat můžeme použít také histogram, ale jeho koše musí respektovat jednotlivé možné hodnoty. Průměr může být smysluplný i tehdy, když sám není možným pozorováním: průměrný počet mláďat může být 2,4, přestože žádné zvíře nemělo „0,4 mládě“.

9.3 Kategoriální nominální proměnná

Kategoriální nominální proměnná (*nominal categorical variable; nominal data*) rozděluje pozorování do kategorií, které nemají přirozené pořadí.

Příklady:

- druh nebo taxonomický řád,

- typ potravy,
- barva květu,
- krevní skupina,
- studijní skupina.

Pro nominální proměnnou obvykle zjišťujeme **četnosti** (*counts/frequencies*) nebo podíly kategorií. Průměr kódů kategorií nedává biologický smysl.

Jak ji uvidíme v R?

```
# Vybereme sloupec s typem potravy.
vec_typ_potravy <- ggplot2::msleep[["vore"]]

# Chybějící údaje označíme viditelnou kategorií.
vec_typ_potravy[is.na(vec_typ_potravy)] <- "neuvedeno"

# Řekneme R, že hodnoty představují kategorie.
vec_typ_potravy <- factor(vec_typ_potravy)

# Zjistíme třídu objektu, jak ji popisuje R.
class(vec_typ_potravy)
```

```
[1] "factor"
```

```
# Zjistíme, jak jsou kategorie technicky uloženy.
typeof(vec_typ_potravy)
```

```
[1] "integer"
```

```
# Zobrazíme strukturu včetně názvů kategorií.
str(vec_typ_potravy)
```


```
Factor w/ 5 levels "carni","herbi",...: 1 5 2 5 2 2 1 4 1 2 ...
```

```
# Spočítáme zastoupení jednotlivých kategorií.
table(vec_typ_potravy)
```

```
vec_typ_potravy
   carn   herbi insecti neuvedeno   omni
    19     32      5         7     20
```


R zobrazuje nominální kategorie jako **factor** s několika úrovněmi (*levels*). `typeof()` přesto vrátí **integer**, protože faktor používá celá čísla jen jako vnitřní kódy pro textové štítky. Tyto kódy nejsou měření a nemá smysl je průměrovat.

9.3.a Četnosti



Obrázek 8: Počet druhů v jednotlivých kategoriích potravy.

9.3.b Podíly



Obrázek 9: Podíl druhů v jednotlivých kategoriích potravy.

Číselný kód není měření

Když lokalitám přidělíme kódy 1, 2 a 3, nevznikne tím numerická proměnná. Výpočet průměru těchto kódů by závisel jen na našem libovolném číslování.

9.4 Kategoriální ordinální proměnná

Kategoriální ordinální proměnná (*ordinal categorical variable; ordinal data*) má kategorie s přirozeným pořadím, ale vzdálenosti mezi nimi nemusí být stejné.

Příklady:

- malý – střední – velký,
- mírný – střední – silný symptom,
- vývojové stadium,
- odpověď na škále „nesouhlasím“ až „souhlasím“,
- stupeň poškození listu.

V datasetu rozlišujeme tři seřazené velikostní kategorie: **lehký – střední – těžký**.

Jak ji uvidíme v R?

```
# Vybereme sloupec s uspořádanou velikostní kategorií.
vec_velikost <- data_savci[["velikost"]]

# Pro tuto ukázkou vynecháme řádky bez uvedené kategorie.
vec_velikost <- vec_velikost[!is.na(vec_velikost)]

# Zjistíme třídu objektu, jak ji popisuje R.
class(vec_velikost)
```

```
[1] "ordered" "factor"
```

```
# Zjistíme, jak jsou kategorie technicky uloženy.
typeof(vec_velikost)
```

```
[1] "integer"
```


```
# Zobrazíme strukturu včetně pořadí kategorií.
str(vec_velikost)
```

```
Ord.factor w/ 3 levels "lehký"<"střední"<...: 3 2 2 1 3 2 3 1 3 3 ...
```

```
# Spočítáme zastoupení jednotlivých kategorií.
table(vec_velikost)
```

```
vec_velikost
  lehký střední těžký
    28     27    28
```

R tento objekt označí třídami **ordered** a **factor**. Vnitřní uložení je opět **integer**, ale pořadí úrovně „lehký“ < „střední“ < „těžký“ je součástí objektu. Právě tím se ordinální faktor liší od nominálního faktoru.



Obrázek 10: U ordinální proměnné zachováváme přirozené pořadí kategorií.

U ordinální proměnné zachováváme pořadí

Kategorie nejsou zaměnitelné: **lehký** < **střední** < **těžký**. Toto pořadí musí zůstat zachované v objektu v R, v tabulce i v grafu.

9.5 Procvičení: určete typ proměnné

Možnosti jsou:

- numerická spojitá;
- numerická diskrétní;
- kategoriální nominální;
- kategoriální ordinální.

Určete typ každé proměnné. Zatím nemusíte vybírat graf:

1. pH vody v rybníce,
2. počet žab odchycených za noc,
3. druh stanoviště,
4. stupeň napadení rostliny: žádný – mírný – silný,
5. identifikační číslo jedince.

Řešení: určete typ proměnné

1. pH: numerická spojitá.
2. Počet žab: numerická diskrétní.
3. Druh stanoviště: kategoriální nominální.
4. Stupeň napadení: kategoriální ordinální.
5. Identifikační číslo: identifikátor, nikoli měřená numerická proměnná.

9.6 Přehled: od typu proměnné k vhodnému popisu

Typ proměnné	Příklad	Vhodný číselný popis	Vhodné grafy	Anglický termín
numerická spojitá	doba spánku	medián + IQR nebo průměr + SD	bodový graf, histogram, hustota, boxplot	<i>continuous numerical</i>
numerická diskrétní	počet mláďat	četnosti; někdy medián/průměr	bodový, sloupcový nebo vhodně nastavený histogram	<i>discrete numerical, count data</i>
kategoriální nominální	typ potravy	četnosti a podíly	sloupcový graf	<i>nominal categorical</i>
kategoriální ordinální	stupeň poškození	četnosti; medián pořadí jen opatrně	uspořádaný sloupcový graf	<i>ordinal categorical</i>

Pořadí rozhodování

1. Co představuje jeden řádek?
2. Co proměnná znamená a jak vznikla?
3. Jakého je typu?
4. Který graf ukáže jednotlivé hodnoty nebo rozdělení?
5. Který číselný souhrn odpovídá tvaru dat a biologické otázce?

10 Shrnutí

V této lekci jsme prošli celou cestu od měření k popisu dat:

1. jedno pozorování jsme zapsali do řádku tabulky;
2. jednu proměnnou jsme vybrali jako vektor v R a zkontrolovali pomocí `length()` a `head()`;
3. před výpočtem statistik jsme se podívali na jednotlivé hodnoty a rozdělení;
4. průměr, medián, kvartily, IQR, minimum, maximum a SD jsme propojili s grafem;
5. krok za krokem jsme z těchto myšlenek postavili krabicový graf;
6. nakonec jsme rozlišili spojitě, diskrétní, nominální a ordinální proměnné.

Neexistuje jedno „nejlepší“ číslo ani jeden „nejlepší“ graf pro všechna data. Pro číselná data často používáme dvě užitečné dvojice: **průměr + SD** nebo **medián + IQR**. Volba závisí na typu proměnné, tvaru dat, pozorovací jednotce a otázce, kterou chceme zodpovědět.

Význam proměnné určuje její statistický typ. Teprve podle něj vybíráme smysluplný graf a číselný souhrn. A stejně jako u titulku o „běžném“ savci platí: správný výpočet ještě nestačí — musíme vidět data a vědět, co představuje jeden řádek.

10.1 Závěrečná otázka

Představte si nový dataset o rostlinách. Každý řádek je jedna rostlina a sloupce obsahují druh, výšku, počet květů a stupeň poškození listů.

Kterou proměnnou byste prozkoumali jako první, jakým grafem a jakou dvojicí statistik?
Dokážete svou volbu zdůvodnit?

11 Most k další lekci

Zatím jsme zkoumali vždy jednu proměnnou. V další lekci se zaměříme na otázku, jak data získat, načíst a uspořádat tak, aby byla připravena pro podobné grafy a výpočty. Později začneme porovnávat skupiny a hledat vztahy mezi proměnnými.

12 Slovníček

Interaktivní definice pojmů jsou dostupné v HTML verzi materiálů a v online slovníčku: <https://cuni-natur-biostatistics.github.io/slovník/>.