

Vizualizace dat a deskriptivní statistika

Podkladové čtenářské materiály k přednášce

26. února 2026

Obsah

1 Úvod	2
2 Naše data — tučňáci z Palmer Station	3
2.1 Sběr dat krok za krokem	3
2.2 Pohled na data	3
3 Vizualizace dat	4
3.1 Proč nejdřív vizualizovat?	4
3.2 Bodový graf (beeswarm)	5
4 Graf	5
5 Kód v R	5
5.1 Histogram	6
6 Graf	6
7 Kód v R	6
7.1 Graf hustoty	8
8 Graf	8
9 Kód v R	8
10 Deskriptivní statistiky	9
10.1 Minimum a maximum	9
11 Minimum na grafu	10
12 Maximum na grafu	11
12.1 Percentily	11
12.2 Medián	12
13 Medián na grafu	13
13.1 Mezikvartilové rozpětí (IQR)	13
14 IQR na grafu	14
14.1 Průměr	15
15 Průměr na grafu	16
15.1 Průměr vs. medián — kdy záleží na rozdílu?	16
15.2 Rozptyl a směrodatná odchylka	17
16 SD jako pásmo ± 1 SD	20
17 Stejný průměr — různá SD	21
18 Statistiky jako vizualizace — krabicový graf	21
18.1 Krok 1: Medián	21

18.2 Krok 2: Krabice (IQR)	22
18.3 Krok 3: Vousy a odlehlé hodnoty	22
18.4 Výsledný krabicový graf	23
19 Boxplot	23
20 Kód v R	23
21 Typy proměnných	24
21.1 Kvantitativní – diskrétní	24
22 Vhodná vizualizace	25
22.1 Kvantitativní – spojité	25
23 Bodový graf	26
24 Histogram	26
25 Graf hustoty	27
25.1 Kategorická – nominální	27
26 Sloupcový graf (počty)	28
27 Sloupcový graf (proporce)	28
27.1 Kategorická – ordinální	28
28 Vhodná vizualizace	29
28.1 Přehled typů proměnných	30
Slovníček pojmů	30

1 Úvod

Tyto materiály slouží jako **textový doprovod k přednášce**. Přečtěte si je před přednáškou, aby vám základní pojmy nezněly cizí, a vraťte se k nim po přednášce, když si budete chtít ujasnit jakýkoliv detail.

Po prostudování těchto materiálů budete schopni:

- Uložit naměřená data do vektoru v R a základně se v nich zorientovat.
- Zvolit vhodný graf pro jeden typ proměnné a vysvětlit, co graf ukazuje.
- Vypočítat a interpretovat základní deskriptivní statistiky (minimum, maximum, průměr, medián, kvartily, IQR, SD).
- Sestavit a přečíst krabicový graf (boxplot).
- Rozlišit typy proměnných a vybrat pro ně odpovídající popis i vizualizaci.

i Jak číst kód v těchto materiálech

Ukázky kódu v R jsou ve výchozím stavu **skryté**. Klikněte na tlačítko „Zobrazit kód v R” pro jejich rozbalení. Kód nemusíte hned spouštět – nejprve ho přečtěte a ujistěte se, že rozumíte, co dělá. Ke spuštění se vrátíte na cvičení.

2 Naše data — tučňáci z Palmer Station

Jako konkrétní datový příklad použijeme data z projektu **Palmer Penguins** — terénní studie ze tří ostrovů u Antarktidy (Biscoe, Dream, Torgersen). Vědci každoročně (2007–2009) počítali tučňáky tří druhů (*Adelie*, *Chinstrap*, *Gentoo*). Naši hlavní proměnnou bude **počet tučňáků zaznamenaných v jednom průzkumu** — jednoduché celé číslo, které ilustruje všechny statistické koncepty z kurzu.

2.1 Sběr dat krok za krokem

Podívejme se na první čtyři průzkumné záznamy:

Průzkum	Počet tučňáků
1	10
2	18
3	16
4	20

V R uložíme tato čtyři čísla do **vektoru** — jednoduché řady hodnot:

```
pocet_tucnaku <-  
  c(10L, 18L, 16L, 20L)  
  
pocet_tucnaku
```

```
[1] 10 18 16 20
```

Jak přidáváme průzkumy, vektor se prodlužuje. My máme celkem **15 průzkumů** (kombinace třech druhů, tří ostrovů a tří let). V těchto materiálech budeme pracovat s vektorem `vzorek_poctu_tucnaku`, který tato data obsahuje. Kdykoli ho uvidíte, jde o naši sadu 15 hodnot.

2.2 Pohled na data

Než začneme počítat statistiky, podívejme se alespoň na prvních deset hodnot:

```
length(vzorek_poctu_tucnaku)
```

```
[1] 15
```

```
head(vzorek_poctu_tucnaku, n = 10)
```

```
[1] 10 18 16 19 16 20 15 16 16 26
```

Vidíme různé hodnoty: 10, 18, 16, ... I těch 15 čísel nám ale samo o sobě moc neřekne o tvaru distribuce. Proto **vizualizujeme**.

3 Vizualizace dat

3.1 Proč nejdřív vizualizovat?

Před tím, než spočítáme jakékoli číslo, bychom se na data měli *podívat*. To není jen zvyk — je to nutnost. Proč?

Mám dvě skupiny tučňáků. Obě mají průměrný počet 7. Výpočty tedy říkají totéž:

```
# Průměr skupiny A  
mean(c(5, 6, 6, 7, 7, 7, 8, 8, 9))
```


```
[1] 7
```

```
# Průměr skupiny B  
mean(c(4, 4, 5, 5, 7, 9, 9, 10, 10))
```

```
[1] 7
```

Obě skupiny mají stejný průměr. Ale podívejme se na rozdělení hodnot:

Stejný průměr — ale úplně jiný tvar dat



Skupina A má hodnoty soustředěné kolem 7 — data jsou symetrická, „hezká“. Skupina B má hodnoty spíše na okrajích — je buď malá, nebo velká, ale málokdy průměrná. To je zásadní biologický rozdíl, který číslo „průměr = 7“ vůbec neodhalí.

⚠ Nikdy nepracujte jen s čísly bez grafu

Čísla mohou klamat. Velmi odlišná data mohou mít stejný průměr i stejnou směrodatnou odchylku. Graf odhalí to, co čísla skrývají. Vždy nejdřív vizualizujte.


3.2 Bodový graf (beeswarm)

Nejpřímochařejší vizualizace: **každý bod = jeden průzkum**. Body jsou mírně rozptýleny do stran – technika se nazývá *beeswarm* (roj včel) – aby se vzájemně nepřekrývaly a zůstaly čitelné.

Co bodový graf ukazuje: vidíme **každou jednotlivou hodnotu**, tvar rozdělení i případná odlehlá pozorování.

4 Graf

15 průzkumů — každý bod je jeden průzkum



5 Kód v R

```
# Jednoduchá alternativa v base R: stripchart
stripchart(
  x = vzorek_poctu_tucnaku,
  method = "jitter",
  pch = 19,
  col = "#8A8A8A",
  xlab = "Počet tučňáků (na průzkum)",
  main = "Bodový graf"
)
```


Co vidíme? Velká většina průzkumů zaznamenala 16–26 tučňáků. Gentoo průzkumy na ostrově Biscoe dosahují vyšších hodnot (34–46). Data jsou mírně asymetrická – například jeden průzkum Adelie na Biscoe zaznamenal jen 10 jedinců.

5.1 Histogram

Histogram **seskupuje hodnoty do košů** (binů) a výška každého sloupce udává četnost průzkumů v daném koši. Šířku koše (binwidth) si volíme sami.

Oproti bodovému grafu histogram nezobrazuje každý bod zvlášť — vidíme tvar distribuce, ale ztratíme přesné hodnoty jednotlivých průzkumů.

6 Graf



7 Kód v R


```
hist(  
  x = vzorek_poctu_tucnaku,  
  breaks = seq(4.5, 49.5, by = 5),  
  col = "#8A8A8A",  
  border = "white",  
  xlab = "Počet tučňáků (na průzkum)",  
  ylab = "Počet průzkumů",  
  main = "Histogram"  
)
```

🔗 Jak volit šířku koše?

Koš (bin) je interval hodnot — například „od 14,5 do 19,5 tučňáků“. Každý průzkum spadne do právě jednoho koše a histogram zobrazí výšku sloupce rovnou četnosti průzkumů v tom koši.

Šířka koše (binwidth) tedy říká, jak velký kus osy x jeden sloupec pokrývá. Volba šířky zásadně mění, co vidíte:

- **Příliš malá šířka** → každý koš obsahuje málo hodnot, graf je „zubatý“, šum překryje signál.
- **Příliš velká šířka** → spousta hodnot se sloučí do jednoho sloupce, přicházíme o detaily tvaru distribuce.



Jak to konkrétně funguje? Při $\text{binwidth} = 5$ a středu koše na 20 zachytí koš všechny hodnoty od 17,5 do 22,5 — tedy průzkumy s asi 20 tučňáky. Při $\text{binwidth} = 10$ by koš zachytil vše od 15 do 25 — sloučí dohromady průzkumy s 16, 18 i 20 tučňáky.

Praktické doporučení:


- Pro **diskrétní** (celočíselná) data jako počet tučňáků: $\text{binwidth} = 5$ — každý koš pokryje přirozené rozmezí hodnot.
- Pro **spojitá** data (délka v mm, hmotnost): experimentujte — začněte s výchozím nastavením R (`breaks = "Sturges"`) a doladte.
- Cíl: koše by měly být dost malé, aby byl vidět tvar distribuce, ale dost velké, aby každý koš obsahoval aspoň několik hodnot.

7.1 Graf hustoty

Graf hustoty je **vyhlazená verze histogramu**. Neukazuje absolutní počty, ale relativní hustotu — kde v osovém prostoru jsou hodnoty nejčastější. Osa y má jednotku „hustota” (density), nikoli „počet průzkumů”.

Prakticky vzato: špička grafu hustoty ukazuje, kde jsou data nejkoncentrovanější.

8 Graf



9 Kód v R

```
hustota_tucnaku <-  
  density(vzorek_poctu_tucnaku)  
  
plot(  
  hustota_tucnaku,  
  xlab = "Počet tučňáků (na průzkum)",  
  ylab = "Hustota",  
  main = "Graf hustoty"  
)
```

Všechny tři grafy — bodový, histogram i hustotní — ukazují tutéž věc z trochu jiné perspektivy. V praxi volte ten, který nejlépe komunikuje váš příběh. Bodový graf je nejupřímnější (vidíte vše), histogram je intuitivní pro počty, hustotní graf je nejhladší pro srovnání tvarů distribucí.

10 Deskriptivní statistiky

Grafy jsou skvělé pro pochopení dat, ale někdy potřebujeme jedno **číslo** — srovnatelné napříč skupinami, reportovatelné v tabulce. Deskriptivní statistiky nám říkají dvě věci: *kde leží střed dat* a *jaká je jejich variabilita*.

Nejdřív si ukážeme výpočty **ručně na malém příkladu**. Použijeme devět průzkumných záznamů:

```
maly_vzorek <-  
c(5L, 6L, 7L, 7L, 8L, 8L, 9L, 10L)
```

i Proč píšeme 5L místo 5?

Když napíšete v R prosté 5, R ho uloží jako **desetinné číslo** (typ `double`, neboli `numeric`): interně je to 5.000000. Přípona L říká R, že jde o **celé číslo** (typ `integer`): 5L je přesně 5, bez desetinné části.

```
typeof(5)    # "double"  
typeof(5L)   # "integer"
```

Proč na tom záleží?

- **Počty tučňáků jsou vždy celá čísla** — průzkum nemůže zaznamenat 7,3 tučňáka. Označení L tuto skutečnost explicitně zakóduje do dat.
- **Paměťová úspornost**: integer zabírá v paměti přibližně polovinu oproti double.
- **Ochrana před překlepem**: R vás upozorní, pokud byste omylem přiřadili desetinnou hodnotu tam, kde je očekáváno celé číslo.

V praxi se L nejčastěji píše u indexů, počtů a jiných celočíselných konstant. Pro délku v mm nebo teplotu bychom L nepísali — tam se očekávají desetinná čísla.

Seřadme je od nejmenšího po největší — to nám pomůže pochopit každou statistiku:

5, 6, 7, 7, 8, 8, 8, 9, 10

Kdykoli uvidíte `vzorek_poctu_tucnaku`, jde o plná data z 15 průzkumů.

10.1 Minimum a maximum

Minimum je nejmenší pozorovaná hodnota. **Maximum** je největší.

Z naší seřazené řady:

- Minimum: **5** — první (nejmenší) hodnota
- Maximum: **10** — poslední (největší) hodnota

Jsou to nejjednodušší statistiky, ale upozorní nás na případné extrémní hodnoty.

```
min(maly_vzorek)
```

```
[1] 5
```

```
max(maly_vzorek)
```

```
[1] 10
```

Na plných datech z 15 průzkumů:

```
min(vzorek_poctu_tucnaku)
```


```
[1] 10
```

```
max(vzorek_poctu_tucnaku)
```

```
[1] 45
```


11 Minimum na grafu

Minimum = 10



12 Maximum na grafu

Maximum = 45



12.1 Percentily

Percentil je hodnota, pod níž leží určitý **podíl dat**. Pracujeme vždy se seřazenou řadou.

Ukažme si to na malém příkladu (5, 6, 7, 7, 8, 8, 8, 9, 10):

- **0. percentil (minimum):** 5 — pod touto hodnotou neleží žádný průzkumový záznam.
- **25. percentil (Q1, dolní kvartil):** R interpoluje a vrátí 7.
- **50. percentil (medián):** Polovina dat leží pod, polovina nad. R vrátí 8.
- **75. percentil (Q3, horní kvartil):** Tři čtvrtiny dat leží pod. R vrátí 8.
- **100. percentil (maximum):** 10.

```
quantile(  
  x = maly_vzorek,  
  probs = c(0, 0.25, 0.50, 0.75, 1)  
)
```

0%	25%	50%	75%	100%
5	7	8	8	10

i Proč percentily nevychází vždy „hezky“?

Výpočet percentilů z malého vzorku vyžaduje interpolaci — odhadujeme polohu mezi hodnotami, které ve skutečnosti nemáme. Proto 25. percentil vychází 7, ačkoli v datech tato přesná hodnota nemusí být. S větším vzorkem vychází výsledky přirozeněji. R nabízí dokonce 9 různých metod výpočtu (`type = 1` až `9`) — výchozí je metoda 7.

12.2 Medián

Medián je **50. percentil** — hodnota, která rozděluje seřazená data přesně napůl.

Číselný příklad. Seřadíme 9 průzkumných záznamů. Prostřední pozice = $(9 + 1) / 2 = 5$. Hodnota na 5. místě je 8.

Čísla v rovnici — všechny hodnoty seřazené, prostřední zvýrazněná:

$$5, 6, 7, 7, \boxed{8}, 8, 8, 9, 10 \Rightarrow \tilde{x} = x_{(\frac{9+1}{2})} = x_{(5)} = 8$$

Obecný vzorec (pro liché n):

$$\tilde{x} = x_{(\frac{n+1}{2})}$$

Kdybychom měli sudé n (např. 8 záznamů), prostřední dvě pozice $n/2$ a $n/2 + 1$ by se zprůměrovaly:

$$\tilde{x} = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$$

```
median(maly_vzorek)
```

```
[1] 8
```


Na plných datech:

```
median(vzorek_poctu_tucnaku)
```

```
[1] 18
```

13 Medián na grafu

Medián = 18



13.1 Mezikvartilové rozpětí (IQR)

Teď víme, kde leží **střed** dat. Ale jak moc jsou data **rozptýlená**?

Jednou z odpovědí je **mezikvartilové rozpětí** (IQR = interquartile range). Je to vzdálenost mezi horním a dolním kvantilem.

Číselný příklad. Z malého příkladu R vrátí $Q_1 = 7$ a $Q_3 = 8$. Vzdálenost = $8 - 7 = 1$ **průzkumných záznamů**.

Čísla v rovnici:

$$\text{IQR} = 8 - 7 = 1$$

Obecný vzorec:

$$\text{IQR} = Q_3 - Q_1$$

To znamená: prostřední polovina (50 %) průzkumů má počet tučňáků v rozmezí 7 až 8.

```
quantile(maly_vzorek, 0.25) # Q1
```

```
25%  
7
```

```
quantile(maly_vzorek, 0.75) # Q3
```

```
75%  
8
```

```
IQR(maly_vzorek) # Q3 - Q1
```

```
[1] 1
```

Na plných datech:

```
quantile(vzorek_poctu_tucnaku, 0.25) # Q1
```

```
25%  
16
```

```
quantile(vzorek_poctu_tucnaku, 0.75) # Q3
```

```
75%  
25
```


```
IQR(vzorek_poctu_tucnaku) # Q3 - Q1
```

```
[1] 9
```

14 IQR na grafu

Q1 = 16, Q3 = 25, IQR = 9

Modrá plocha = prostřední 50 % dat



💡 Kdy použít IQR místo SD?

IQR je **odolné vůči odlehlým hodnotám**. Pokud máte data s extrémními hodnotami, nebo pokud jsou data výrazně asymetrická, IQR je bezpečnější volbou než směrodatná odchylka. Pro ordinální data (stupně poškození, škály souhlasu) je IQR prakticky jedinou smysluplnou mírou variability.

14.1 Průměr

Průměr (mean) je nejznámější statistika. Mechanicky: sečteme všechny hodnoty a vydělíme jejich počtem.

Číselný příklad. Sečteme všech 9 hodnot a vydělíme jejich počtem.

Čísla v rovnici:

$$\bar{x} = \frac{5 + 6 + 7 + 7 + 8 + 8 + 8 + 9 + 10}{9} = \frac{68}{9} = 7.56$$

Obecný vzorec:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

```
# Ručně: součet děleno počet  
sum(maly_vzorek) / length(maly_vzorek)
```

```
[1] 7.555556
```

```
# Zkráceně pomocí funkce  
mean(maly_vzorek)
```

```
[1] 7.555556
```


Na plných datech:

```
round(  
  mean(vzorek_poctu_tucnaku),  
  digits = 2  
)
```

```
[1] 22.2
```

15 Průměr na grafu

Průměr = 22.2



15.1 Průměr vs. medián — kdy záleží na rozdílu?

Průměr a medián měří „střed“ dat různými způsoby. Většinou jsou si podobné — ale ne vždy. A ten rozdíl může být biologicky důležitý.

Představme si, že jsme registrovali **neobvykle velký průzkum s 90 tučňáky** — možná rozšíření sledované oblasti nebo výjimečně příznivá sezóna. Přidáme ho do dat:

```
# Bez odlehlé hodnoty  
mean(vzorek_poctu_tucnaku)
```

```
[1] 22.2
```


```
median(vzorek_poctu_tucnaku)
```

```
[1] 18
```

```
# S odlehlou hodnotou (90 tučňáků)  
mean(pocet_tucnaku_outlier)
```

```
[1] 26.4375
```

```
median(pocet_tucnaku_outlier)
```

Průměr se posunul — jeden extrémní průzkum ho „přitáhl“ ke své hodnotě. Medián se skoro nezměnil.

⚠ Průměr může být zavádějící

Průměr je „přitahován“ odlehlými hodnotami. V ekologii s nimi pracujeme neustále: počty druhů na lokalitách (jedna lokalita může být extrémně bohatá), velikosti těl v populaci, nebo množství srážek (jedno extrémní sucho nebo povodeň). Pokud máte podezření na odlehlé hodnoty nebo asymetrická data, preferujte **medián** jako míru středu.

i Kdy je průměr lepší volbou?

Průměr je matematicky pohodlný a dobře se chová, když jsou data přibližně **symetricky rozložená** kolem středu (bez výrazných odlehlých hodnot). Právě takový tvar vidíme u počtu tučňáků na průzkum — proto průměr a medián vychází velmi podobně.

Průměr je také základní stavební kámen statistického modelování. Lineární model (`lm()`), který budeme používat po celý kurz, počítá průměry skupin a průměrné efekty prediktorů. Je tedy důležité chápat, kdy průměru věřit a kdy být obezřetní.

15.2 Rozptyl a směrodatná odchylka

Víme, kde leží střed dat. Teď chceme vědět, jak moc jsou data **rozptýlená kolem středu**. K tomu používáme rozptyl a směrodatnou odchylku.

Intuice: spočítejme, jak daleko je každá hodnota od průměru. Tuto vzdálenost nazýváme **odchylka** (residuum, chyba).

Číselný příklad. Průměr malého příkladu = 7.56. Pro první průzkumový záznam (hodnota 5): $5 - 7.56 = -2.56$. Celý přehled pro všechny záznamy:

Průzkum	Počet tučňáků	Průměr ($\bar{x}$)	Odchylka ($x_i - \bar{x}$)	Odchylka ²
1	5	7.56	-2.56	6.53
2	6	7.56	-1.56	2.42
3	7	7.56	-0.56	0.31
4	7	7.56	-0.56	0.31
5	8	7.56	0.44	0.20
6	8	7.56	0.44	0.20
7	8	7.56	0.44	0.20
8	9	7.56	1.44	2.09
9	10	7.56	2.44	5.98

Číslo v rovnici (příklad pro první průzkumový záznam):

$$e_1 = 5 - 7.56 = -2.56$$

Obecný vzorec:

$$e_i = x_i - \bar{x}$$

Součet všech odchylek = 0 — záporné a kladné se vždy vyruší.

Jednoduché řešení by bylo vzít **absolutní hodnoty** odchylek (ignorovat znaménko) a ty sečíst. To skutečně dává smysluplné číslo zvané „průměrná absolutní odchylka“. Nicméně statistika tradičně volí jiný postup: odchylky **umocníme**. Proč?

1. **Zbavíme se znaménka:** $(-2, 56)^2 = 6, 55$ — záporné odchylky se stanou kladnými, stejně jako kladné.
2. **Velké odchylky jsou penalizovány víc:** Průzkum vzdálený 3 tučňáky od průměru přispívá $3^2 = 9$ do součtu. Tři průzkumy každý o 1 tučňáka vzdálené přispívají $3 \times 1^2 = 3$. Díky tomu SD „cítí“ outlery a silně asymetrická data — stejnou vlastnost, za kterou jsme kritizovali průměr, ale tentokrát ji využijeme záměrně.
3. **Matematická pohodlnost:** Kvadrát je hladká funkce vhodná pro derivaci a optimalizaci — to se hodí v pokročilejší statistice.

Součet čtverců odchylek (anglicky *sum of squares*, zkratka SS) je tedy součet hodnot ze sloupce Odchylka² v tabulce.

Číslo v rovnici:

$$\begin{aligned}
 SS &= (5 - 7.56)^2 + (6 - 7.56)^2 + (7 - 7.56)^2 + (7 - 7.56)^2 + (8 - 7.56)^2 + (8 - 7.56)^2 + (8 - 7.56)^2 + (9 - 7.56)^2 + (10 - 7.56)^2 \\
 &= 6.53 + 2.42 + 0.31 + 0.31 + 0.2 + 0.2 + 0.2 + 2.09 + 5.98 \\
 &= 18.22
 \end{aligned}$$

Obecný vzorec:

$$SS = \sum_{i=1}^n (x_i - \bar{x})^2$$

Číselný příklad. Rozptyl = $SS / (n - 1) = 18.22 / 8 = \mathbf{2.28}$.

Číslo v rovnici:

$$s^2 = \frac{6.53 + 2.42 + 0.31 + 0.31 + 0.2 + 0.2 + 0.2 + 2.09 + 5.98}{9 - 1} = \frac{18.22}{8} = 2.28$$

Obecný vzorec:

$$s^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2$$

(Dělíme $n - 1$ místo n , protože odhadujeme rozptyl celé populace z vzorku. K tomu se vrátíme v přednášce o inferenci.)

Ale rozptyl je v **kvadrátových jednotkách** – tučňáci², což je fyzikálně nesmyslné. Proto vezmeme odmocninu.

Číselný příklad. $SD = \sqrt{2.28} = \mathbf{1.51}$ tučňáka.

Číslo v rovnici:

$$s = \sqrt{\frac{18.22}{8}} = \sqrt{2.28} = 1.51$$

Obecný vzorec:

$$s = \sqrt{s^2}$$

To znamená: typický průzkumový záznam se od průměru odchyluje o přibližně 1.5 tučňáka.

```
var(maly_vzorek) # rozptyl (variance)
```

```
[1] 2.277778
```

```
sd(maly_vzorek) # směrodatná odchylka
```

```
[1] 1.509231
```

Na plných datech:

```
round(sd(vzorek_poctu_tucnaku), digits = 2)
```

```
[1] 10.04
```


Co toto číslo znamená **graficky**? Níže jsou dva pohledy:

- **Levý graf** zobrazuje průzkumy jako body. Červená přerušovaná čára je průměr, červené pásmo je rozsah průměr ± 1 SD. Zhruba dvě třetiny průzkumů leží uvnitř tohoto pásma — to je základní vlastnost dat blízkých normálnímu rozdělení.
- **Pravý graf** porovnává dvě skupiny se **stejným průměrem**, ale různou SD. Všimněte si, jak širší SD znamená roztáhlejší, plošší histogram.

16 SD jako pásmo ± 1 SD


Průměr = 22.2, SD = 10

Červené pásmo = průměr ± 1 SD



17 Stejný průměr — různá SD

Obě skupiny mají průměr = 8 — liší se jen variabilitou



i Co SD znamená biologicky?

Představte si dvě populace ptáků se stejnou průměrnou délkou křídla 20 cm. První populace má $SD = 0,5$ cm, druhá $SD = 3$ cm. První populace je velmi uniformní — možná žije v homogenním prostředí pod silnou stabilizující selekcí. Druhá populace je variabilnější — možná jde o smíšenou populaci, nebo zažívají různorodé selekční tlaky.

SD tedy není jen „chyba měření“ — obsahuje **biologickou informaci o variabilitě v populaci**. Menší SD neznamená „lepší data“, jen uniformnější populaci.


18 Statistiky jako vizualizace — krabicový graf

Všechny statistiky, které jsme spočítali (min, max, percentily, medián, IQR), lze nakreslit jako jeden přehledný graf: krabicový graf (boxplot). Pojďme ho sestavit krok za krokem, aby bylo jasné, co každý prvek znamená.

18.1 Krok 1: Medián

Začneme s tím, co již umíme — narýsujeme vodorovnou čáru na pozici mediánu:


Krok 1: Medián = 18



18.2 Krok 2: Krabice (IQR)

Přidáme obdélník od Q1 do Q3 — to je vlastní „krabice” (box):


Krok 2: Krabice = IQR ($Q1 = 16$, $Q3 = 25$)



18.3 Krok 3: Vousy a odlehlé hodnoty

Vousy sahají od hran krabice maximálně o $1,5 \times \text{IQR}$ dál. Body mimo vousy jsou odlehlá pozorování — kreslí se jako separátní body:

Krok 3: Vousy ($1,5 \times \text{IQR}$) + odlehlé hodnoty (červeně)




18.4 Výsledný krabicový graf

Takto vypadá výsledný boxplot, jak ho generuje R automaticky — tentýž tvar, jen nakreslený jedním příkazem:

19 Boxplot

Krabicový graf



20 Kód v R

```
boxplot(
  x = vzorek_poctu_tucnaku,
  horizontal = TRUE,
  col = "#8A8A8A",
  xlab = "Počet tučňáků (na průzkum)",
```

```
main = "Krabicový graf"
)
```

Jak číst boxplot – přehled prvků:

Prvek	Co znamená
Tlustá čára uprostřed	Medián (50. percentil)
Krabice	Prostřední 50 % dat (Q1 až Q3, tedy IQR)
Vousy	Data do vzdálenosti 1,5× IQR od krabice
Osamělé body	Odlehlé hodnoty (přesahují vousy)

i Boxplot je nejlepší graf pro srovnání skupin

Zatímco histogramy a beeswarm grafy jsou skvělé pro zobrazení **jednoho** rozdělení, boxploty excelují, když chceme **porovnat více skupin** vedle sebe. Uvidíte to v dalších přednáškách – například když budeme srovnávat počty tučňáků na různých lokalitách nebo v různých letech.

21 Typy proměnných

Ne všechna data jsou čísla. A ne všechna čísla jsou si rovna. Typ proměnné určuje, jaký graf zvolíme, jakou statistiku spočítáme a jaký model použijeme.

Budeme rozlišovat numerické proměnné a kategoriální proměnné; každá z nich vyžaduje jiný popis i jiný graf.

21.1 Kvantitativní – diskrétní

Diskrétní proměnné nabývají pouze **celočíslných hodnot** – mezi nimi není žádná platná hodnota.

Biologické příklady:

- Počet tučňáků (na průzkum): 10, 18, 16, 20, ...
- Počet druhů ptáků na lokalitě
- Počet vajec v hnízdě
- Počet jedinců v populaci

Nelze mít 7,3 tučňáka ani 4,7 vejce. Příroda „skáče“ po celých číslech.


```
pocet_tucnaku_ukazka <-
  c(10L, 18L, 16L, 20L) # sufix L = celé číslo (integer)
```



```
class(pocet_tucnaku_ukazka)
```

```
[1] "integer"
```

22 Vhodná vizualizace




22.1 Kvantitativní — spojité

Spojité proměnné mohou nabývat **jakékoli hodnoty** v intervalu. Přesnost závisí jen na měřicím přístroji.

Biologické příklady:

- Délka zobáku v mm (39,1 mm, 40,3 mm, ...)
- Teplota vzduchu
- Hmotnost živočicha
- Koncentrace chlorofylu v listu



Obrázek 1: Schéma měření zobáku (culmen) tučňáka. Zdroj: Allison Horst.


```
delka_zobaku_ukazka <-  
  c(39.1, 40.3, 36.7, 42.9) # desetinná čísla  
  
class(delka_zobaku_ukazka)
```

```
[1] "numeric"
```

Pro spojitá data máme více vizualizačních možností — každá odhalí trochu jiný aspekt:


23 Bodový graf

Bodový graf — každý bod je jeden tučňák




24 Histogram

Histogram — koše po 1 mm



25 Graf hustoty



25.1 Kategorická — nominální

Nominální proměnné mají kategorie, **které nelze seřadit** — žádná není „větší“ ani „lepší“ než jiná.

Biologické příklady:


- Druh tučňáka (Adelie, Chinstrap, Gentoo)
- Druh opylovače (včela, čmelák, motýl)
- Typ stanoviště (les, louka, mokřad)
- Krevní skupina (A, B, AB, 0)

```
druh_ukazka <-  
  c("Adelie", "Chinstrap", "Adelie", "Gentoo")  
  
class(druh_ukazka)
```


```
[1] "character"
```

Každá kategorie dostane vlastní barvu — vizuální kód, který odpovídá realitě:

26 Sloupcový graf (počty)



27 Sloupcový graf (proporce)



27.1 Kategorická — ordinální

Ordinální proměnné mají kategorie, **které jdou seřadit** — ale vzdálenosti mezi stupni nejsou nutně stejné.

Biologické příklady:

- Hmotnostní kategorie tučňáka (malý, střední, velký)
- Školní klasifikace (1, 2, 3, 4, 5)
- Souhlas s výrokem (zcela souhlasím → zcela nesouhlasím)
- Pokryvnost vegetace (0–5 %, 5–25 %, 25–50 %, ...)


```
# Klíčové: levels musí být seřazené!
hmotnost_ukazka <-
  factor(
    x = c("střední", "velký", "malý", "velký"),
    levels = c("malý", "střední", "velký"),
    ordered = TRUE
  )

hmotnost_ukazka
```

```
[1] střední velký malý velký
Levels: malý < střední < velký
```

R hlásí Levels: malý < střední < velký — znaménko < ukazuje pořadí.

28 Vhodná vizualizace



! Ordinální data jako čísla — opatrně!

Ordinální data jsou někdy zakódována jako čísla (1 = malý, 2 = střední, 3 = velký). Může být lákavé spočítat průměr a říci „průměrná kategorie = 1,7“. Ale to předpokládá, že rozdíl mezi „malým“ a „středním“ tučňákem je stejně velký jako mezi „středním“ a „velkým“ — a to nevíme. Pro ordinální data preferujte **medián a IQR**, nebo speciální ordinální modely.

28.1 Přehled typů proměnných

Typ	Biologické příklady		Střed	Variabilita	Vhodný graf
Kvant. diskrétní	počet druhů	počet tučňáků	průměr/ medián	SD / IQR	histogram, beeswarm
Kvant. spojitě	délka, teplota, hmotnost		průměr/ medián	SD / IQR	histogram, boxplot, hustota
Kategorická nominální	barva, druh, typ stanoviště		modus	četnosti	sloupcový graf
Kategorická ordinální	hmotnostní škála	kategorie	medián	IQR	sloupcový graf (seřazený)

❓ Proč typ proměnné tak záleží?

Typ proměnné určuje:

1. **Jaký graf** zvolíme — histogram pro čísla, sloupcový pro kategorie.
2. **Jakou statistiku** počítáme — průměr pro symetrická čísla, medián nebo modus pro ostatní.
3. **Jaký statistický model** použijeme — lineární model pro číselné odezvy, logistická regrese pro dichotomické kategorie, ordinální model pro seřazené kategorie.

Záměna typů proměnných je jedním z nejčastějších zdrojů chyb v analýze dat. Vždy si nejdřív ujasněte, co vlastně měříte.

Materiály jsou průběžně aktualizovány. Datum poslední úpravy viz záhlaví.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice: