

Vizualizace dat a deskriptivní statistika

Biostatistika - L-example

 Ondřej Mottl

Moodle

Výsledky učení

Po absolvování této přednášky budete schopni:

- Rozlišit typy proměnných
- Zvolit odpovídající popis dat (deskriptivní statistiky)
- Zvolit vhodnou vizualizaci dat (grafy)
- Popsat variabilitu dat (rozptyl, směrodatná odchylka)
- Rozlišit typy proměnných a vybrat odpovídající graf


Naše biologická otázka

Chceme vědět: **Jak velké jsou kolonie tučňáků na různých ostrovech Antarktidy?**

Jsou kolonie přibližně stejně velké, nebo se výrazně liší?

Naše data

Tučňáci z Palmer Station



Artwork by Allison Horst

Palmer Penguins

Vědci z projektu Palmer Penguins každoročně prováděli průzkumy tučňáků na třech ostrovech u Antarktidy.

U každého průzkumu si zapsali **počet tučňáků**.

Palmer Penguins

Zapisujeme si počet tučňáků z průzkumu. Můžeme mít 10, 16, 18, 20, ... tučňáků.

Průzkum	Počet tučňáků
1	10

Palmer Penguins

Zapisujeme si počet tučňáků z průzkumu. Můžeme mít 10, 16, 18, 20, ... tučňáků.

Průzkum	Počet tučňáků
1	10
2	18

Palmer Penguins

Zapisujeme si počet tučňáků z průzkumu. Můžeme mít 10, 16, 18, 20, ... tučňáků.

Průzkum	Počet tučňáků
1	10
2	18
3	16

Palmer Penguins

Zapisujeme si počet tučňáků z průzkumu. Můžeme mít 10, 16, 18, 20, ... tučňáků.

Průzkum	Počet tučňáků
1	10
2	18
3	16
4	20

Palmer Penguins

Zapisujeme si počet tučňáků z průzkumu. Můžeme mít 10, 16, 18, 20, ... tučňáků.

Průzkum	Počet tučňáků
1	10
2	18
3	16
4	20
...	...

Otázka k zamyšlení

Víme, že máme 15 průzkumů s různými počty tučňáků. Jak bychom tato data uložili v R?

- a. 15 samostatných proměnných (`pruzkum_1 ← 10`, `pruzkum_2 ← 18`, ...)
- b. Jeden vektor: `c(10, 18, 16, ...)`
- c. Tabulku se dvěma sloupci

Palmer Penguins

```
1 pocet_tucnaku <-  
2   c(  
3     10L # průzkum 1  
4   )
```

Průzkum	Počet tučňáků
---------	---------------

1	10
---	----

Palmer Penguins

```
1 pocet_tucnaku <-  
2   c(  
3     10L, # průzkum 1  
4     18L # průzkum 2  
5   )
```

Průzkum	Počet tučňáků
1	10
2	18

Palmer Penguins

```
1 pocet_tucnaku <-  
2   c(  
3     10L, # průzkum 1  
4     18L, # průzkum 2  
5     16L, # průzkum 3  
6     20L, # průzkum 4  
7     ... # další průzkumy  
8   )
```

Průzkum	Počet tučňáků
1	10
2	18
3	16
4	20
...	...


Naše data

Získali jsme 15 průzkumových záznamů a zapsali počet tučňáků u každého z nich.

Průzkum č. 1 z 15



Naše data



Co vidíme v datech?



Než pokračujeme — zapište si jednu věc, co z grafu vidíte.

- Kde jsou průzkumy nejkoncentrovanější?
- Jsou v datech nějaké neobvyklé hodnoty?
- Jsou všechny průzkumy podobně velké, nebo jsou velké rozdíly?

Naše data

Nyní máme data. Jak je **vizualizovat**?

Vizualizace dat

Proč nejdřív vizualizovat?

Dva vědci zkoumají kolonie tučňáků na dvou různých ostrovech. **Oba naměřili průměrný počet 7 tučňáků na průzkum. Jsou ostrovy biologicky stejné?**


```
1 # Průměr - ostrov A
2 mean(c(5, 6, 6, 7, 7, 7, 8, 8, 9))
```

```
[1] 7
```

```
1 # Průměr - ostrov B
2 mean(c(4, 4, 5, 5, 7, 9, 9, 10, 10))
```

```
[1] 7
```

Proč nejdřív vizualizovat?




Ostrov A má průzkumy soustředěné kolem 7 – symetrická, stabilní kolonie. Ostrov B má průzkumy buď velmi malé, nebo velmi velké – to může signalizovat sezónní rozdíly nebo nestabilitu kolonie. **Stejné číslo, zásadně odlišná biologie.**

Proč nejdřív vizualizovat?

Vždy nejdřív vizualizujte.

Bodový graf (beeswarm)

Každý bod = jeden průzkum. Vidíme **všechna data** najednou.



- vidíme **každou hodnotu** zvlášť
- odhaluje **tvar distribuce** (kde jsou hodnoty nahloučené)
- snadno odhalí **odlehlé hodnoty**


Otázka k zamyšlení

Bodový graf ukazuje každý průzkum zvlášť. Kdybychom průzkumy seskupili do „košů“ po 5 tučňácích, co by znázorňovala výška sloupce?

- a. Průměrný počet tučňáků v daném koši
- b. Počet průzkumů, které spadají do daného koše
- c. Celkový počet tučňáků v daném koši

Histogram


Skupinujeme průzkumy do „košů“ podle počtu tučňáků. Výška sloupce = počet průzkumů v daném koši.



- ukazuje, kde jsou hodnoty **nahloučené**
- odhaluje **symetrii** nebo asymetrii distribuce
- závisí na šířce koše (`binwidth`) – vyzkoušejte různé hodnoty


Graf hustoty

Graf hustoty (density plot) je „vyhlazený“ histogram – neukazuje počty, ale **relativní četnost** hodnot.



- „vyhlazená“ verze histogramu – nezávisí na šířce koše
- ukazuje **relativní četnost**: kde jsou hodnoty pravděpodobnější
- vhodný pro porovnání **více skupin** najednou

Jak interpretujeme tento graf?



Co o datech sděluje tento histogram?

- Kde jsou průzkumy nejčastější?
- Je distribuce symetrická nebo asymetrická?
- Který graf (bodový / histogram / hustota) byl pro vás nejinformativnější?

Deskriptivní statistiky

Čísla místo obrázků

Grafy jsou skvělé — ale v publikaci nebo při srovnání desítek skupin potřebujeme data popsat **jedním číslem**. Jaké číslo zvolit?


Deskriptivní statistiky

Minimum

Minimum nám říká, kolik tučňáků měl průzkum s nejnižším počtem tučňáků.

```
1 min(pocet_tucnaku)
```

```
[1] 10
```



Deskriptivní statistiky

Maximum

Maximum nám říká, kolik tučňáků měl průzkum s nejvyšším počtem tučňáků.

```
1 max(pocet_tucnaku)
```

```
[1] 45
```



Percentily

Percentil říká, jakou hodnotu nepřesahuje dané procento dat.

- **0. percentil** = minimum
- **50. percentil** = polovina průzkumů má méně, polovina více
- **100. percentil** = maximum

```
1 quantile(pocet_tucnaku, probs = c(0, 0.25, 0.50, 0.75, 1))
```

0%	25%	50%	75%	100%
10	16	18	25	45

Percentily rozdělují data na části – 25. a 75. percentil jsou zvláště důležité.


Deskriptivní statistiky

Medián

Medián je **50. percentil** – polovina průzkumů má méně tučňáků, polovina více.

```
1 median(pocet_tucnaku)
```

```
[1] 18
```



Mezikvartilové rozpětí (IQR)

Q1 = 25. percentil, **Q3** = 75. percentil.

IQR = **Q3** - **Q1** – rozpětí prostřední poloviny dat.

```
1 quantile(pocet_tucnaku, 0.25) # Q1
```

25%

16

```
1 quantile(pocet_tucnaku, 0.75) # Q3
```


75%

25

```
1 IQR(pocet_tucnaku) # Q3 - Q1
```

[1] 9

Q1: 16, Q3: 25, IQR: 9



IQR je odolný vůči odlehlým hodnotám – popisuje **prostřední 50 %** dat.


Deskriptivní statistiky

Průměr

Průměr (mean) nám říká, jaký je typický počet tučňáků přes všechny průzkumy.

```
1 mean(pocet_tucnaku)
```

```
[1] 22.2
```



Otázka k zamyšlení

Přidáme do dat jeden průzkum s **90 tučňáky**. Jak se změní průměr a medián?

- a. Oba se zvýší přibližně stejně
- b. Průměr se zvýší výrazně, medián jen mírně
- c. Medián se zvýší výrazně, průměr jen mírně

Průměr vs. Medián

Průměr a medián mohou být velmi odlišné, pokud jsou v datech **odlehlé hodnoty** (outliers).

Co kdybychom přidali neobyčlý průzkum s 90 tučňáky?

```
1 mean(pocet_tucnaku)
```

```
[1] 22.2
```

```
1 median(pocet_tucnaku)
```

```
[1] 18
```

```
1 mean(pocet_tucnaku_outlier)
```

```
[1] 26.4375
```

```
1 median(pocet_tucnaku_outlier)
```

```
[1] 18.5
```

Bez odlehlé hodnoty

S odlehlou hodnotou

Průměr je citlivý na odlehlé hodnoty. Medián je odolnější – popisuje „typický“ případ lépe, pokud data nejsou symetrická.

Rozptyl a směrodatná odchylka

Min, max, průměr a medián nám říkají, kde jsou data. Ale jak moc jsou data **rozptýlena**?

Směrodatná odchylka (standard deviation) nám říká, jak daleko jsou typicky hodnoty od průměru.


```
1 sd(pocet_tucnaku)
```

```
[1] 10.04419
```

```
1 var(pocet_tucnaku)
```


```
[1] 100.8857
```

Rozptyl (variance) = SD^2 . V praxi se většinou používá SD – je ve stejných jednotkách jako data.



Proč je SD důležité?

Dvě skupiny průzkumů mohou mít **stejný průměr**, ale velmi **různě rozptýlená** data.




Stejný průměr $\neq$ stejná data. Směrodatná odchylka nám říká, jak moc jsou data „roztažená“.

Statistiky jako vizualizace

Od statistik ke grafu

Průměr – SD jsme viděli jako čísla a jako pásmo na grafu.



Od statistik ke grafu

Co kdybychom statistiky **nakreslili jako tvar**?

Krabicový graf (boxplot) – krok 1

Začneme s tím, co už známe: **medián**.


Medián: 18



Krabicový graf (boxplot) – krok 2


Přidáme **mezikvartilové rozpětí** (IQR): od 25. do 75. percentilu.

Medián: 18, Q1: 16, Q3: 25, IQR: 9



Krabicový graf (boxplot) – krok 3


Přidáme **vousy** ($1,5 \times \text{IQR}$ od krabice) a **odlehlé hodnoty** (body mimo vousy).



- Tlustá čára = **medián**
- Krabice = **IQR** (Q1–Q3)
- Vousy = $1,5 \times \text{IQR}$ od krabice
- Body = **odlehlé hodnoty**

Toto je standardní ggplot2 boxplot – totéž, akorát nakreslený automaticky.

Krabicový graf



Boxplot není nový koncept – je to jen statistiky, které znáte, nakreslený jako tvar.

Diskuze se sousedem (2 min)

Kamarád říká: „Přece víme průměr a SD — proč bychom kreslili boxplot?“

Diskutujte se sousedem. Co byste mu odpověděli?

Typy proměnných

Proč rozlišujeme typy proměnných?

Typ proměnné určuje:

- jaké **statistiky** dávají smysl (průměr počtu tučňáků ano; průměr druhu tučňáka ne)
- jakou **vizualizaci** zvolíme (beeswarm pro čísla, sloupcový graf pro kategorie)
- jak data správně **interpretujeme**

Kvantitativní – diskrétní


- počet tučňáků na průzkum
- počet stromů v lese
- počet druhů ptáků na lokalitě
- počet planet ve Sluneční soustavě

Proměnná nabývající pouze **celočíselných** hodnot – nelze mít 7,3 stromu.

Kvantitativní – diskrétní

```
1 pocet_tucnaku <-  
2 c(10L, 18L, 16L, 20L) # celá čísla
```


Vizualizace: beeswarm nebo histogram.



Kvantitativní – spojitá

- délka zobáku tučňáka v mm
- teplota vzduchu
- množství srážek
- hmotnost zvířete

Proměnná nabývající **jakékoli hodnoty** v intervalu – délka může být 39,1 mm nebo 40,34 mm.




Kvantitativní – spojitá


```
1 delka_zobaku <-  
2   c(39.1, 40.3, 36.7, 42.9) # desetinná čísla
```

Různé vizualizace odhalují různé vlastnosti dat.


Bodový graf



Histogram



Graf hustoty



Otázka k zamyšlení

Vědci zapsali **druh tučňáka** u každého jedince: *Adelie*, *Chinstrap*, *Gentoo*.
Má smysl spočítat **průměrný druh tučňáka**?

- a. Ano — průměr funguje pro jakákoliv data
- b. Ne — druh tučňáka je kategorie, průměr nedává smysl
- c. Záleží na tom, kolik druhů máme

Průměr lze spočítat jen pro **kvantitativní** proměnné. Pro kategorické proměnné používáme četnosti, podíly nebo modus.

Kategorická – nominální


- druh tučňáka (Adelie, Chinstrap, Gentoo)
- druh hmyzu (včela, čmelák, motýl)
- typ stanoviště (les, louka, mokřad)
- krevní skupina (A, B, AB, 0)

Proměnná, jejíž hodnoty **nelze seřadit** – „Adelie“ není více ani méně než „Chinstrap“.

Kategorická – nominální

```
1 druh_tucnaku <-  
2   c("Adelie", "Chinstrap", "Adelie", "Gentoo")
```


Každá kategorie dostane vlastní barvu – vizuální kód odpovídá realitě.



Kategorická – nominální

Chceme ukázat **proporce** (ne počty)? Použijeme složený sloupcový graf nebo waffle.

Složený sloupcový graf



Kategorická – ordinální


- hmotnostní kategorie tučňáka (malý, střední, velký)
- školní klasifikace (1, 2, 3, 4, 5)
- souhlas s výrokiem (zcela souhlasím – zcela nesouhlasím)
- fáze měsíce (nový – úplněk)

Proměnná s **pořadím**, ale vzdálenost mezi stupni **není nutně stejná** – „velký“ není přesně dvakrát víc než „malý“.

Kategorická – ordinální

```
1 kategorie_hmotnosti <-  
2   factor(  
3     c("střední", "velký", "malý", "velký"),  
4     levels = c("malý", "střední", "velký"),  
5     ordered = TRUE  
6   )
```

Vizualizace: sloupcový graf s **seřazenou** osou.



Závěr

Shrnutí

- **Na tučňácích jsme viděli:** stejný průměr může skrývat zásadně odlišnou biologii — proto vždy nejdřív vizualizujeme
- **Vždy nejdřív vizualizujte** — grafy odhalují, co čísla skrývají
- **Průměr je citlivý na odlehlé hodnoty** — medián je odolnější
- **Boxplot** shrnuje medián, IQR, vousy a odlehlé hodnoty najednou
- **Typ proměnné** určuje správnou statistiku i vizualizaci
- **Střed $\neq$ popis variability** — potřebujeme obojí

Závěrečná otázka

Kdy byste **nepoužili průměr**?

- Kdy data obsahují odlehlé hodnoty
- Kdy je distribuce silně asymetrická
- Kdy chcete popsat „typický“ případ ve zkosených datech