

# Co váží „typický“ savec?

Biostatistika

 Ondřej Mottl

Moodle

# Kolik váží běžný savec?

## SMYŠLENÝ TITULEK A

### Vědci spočítali:

„Průměrný (*mean*) savec váží **166 kg**.“

## SMYŠLENÝ TITULEK B

### Jiná analýza tvrdí:

„Běžný savec (*median*) váží jen **1,67 kg**.“

*Stejná tabulka. Dvě dramaticky odlišná čísla.*

# Výsledky učení

Po dnešní přednášce budete schopni:

- vysvětlit, co v tabulce představuje **jeden řádek**
- přečíst vhodný **graf jedné proměnné**
- vybrat smysluplnou dvojici **středu** a **rozptýlení**
- rozlišit čtyři **typy proměnných** a zvolit jejich první popis
- vysvětlit, proč jedno správně vypočtené číslo ještě nemusí být dobrý titulek

# Jak budeme dnes pracovat?

Otázka → data → graf → souhrn → opatrná interpretace

## NA PŘEDNÁŠCE

Budete odhadovat, hlasovat,  
porovnávat grafy a obhajovat závěry.

## V MATERIÁLECH

HTML nabízí záložky a rozbalovací  
otázky; PDF je vhodné pro souvislé  
čtení.



# Hlasování: který titulek je správný?

## TITULEK A

„Průměrný savec váží **166 kg.**“

## TITULEK B

„Běžný savec váží **1,67 kg.**“

**Nejdřív hlasujte sami. Potom svoji volbu obhájte sousedovi.**

**A)** Pouze titulek A.

**B)** Pouze titulek B.

**C)** Oba mohou být správně.

**D)** Zatím nemáme dost informací.

Když nehlasujeme: napište si jednu informaci, kterou potřebujete znát, než titulku uvěříte.

# Přesvědčte souseda

**Proč jste vybrali právě svoji možnost?**

## **DŮKAZ, KTERÝ MÁTE K DISPOZICI**

- stejná tabulka savců;
- 166 kg versus 1,67 kg;
- zatím nevíme, jak hodnoty vypadají.

# Odpověď zatím odložíme

Nejdřív zjistíme, **co bylo změřeno** a **jak hodnoty vypadají**.

Správný výpočet ještě nezaručuje správnou interpretaci.

# Od organismu k datům

# Začneme jedním savcem

## Gepard (*Cheetah*)

Výzkumníci studovali spánkové návyky savců a u geparda zaznamenali **12.1 hodiny spánku za den**.

### PŘI ZÁZNAMU MĚŘENÍ

Výsledek pro jeden zastoupený druh zapíšeme do jednoho řádku tabulky.



Ilustrace vytvořená pomocí AI.

# První pozorování přidá první řádek

| Druh (species) | Spánek za den (h) |
|----------------|-------------------|
| Cheetah        | 12.1              |

Jeden řádek zachovává spojení mezi **druhem** a jeho **hodnotou**.

# Další druh přidá další řádek

| Druh (species) | Spánek za den (h) |
|----------------|-------------------|
| Cheetah        | 12.1              |
| Owl monkey     | 17.0              |

Tabulka roste **po řádcích**: jeden zastoupený druh po druhém.

# Čtyři druhy, čtyři řádky

| Druh (species)             | Spánek za den (h) |
|----------------------------|-------------------|
| Cheetah                    | 12.1              |
| Owl monkey                 | 17.0              |
| Mountain beaver            | 14.4              |
| Greater short-tailed shrew | 14.9              |

*Na co přesně se vztahuje hodnota 12,1 hodiny v prvním řádku?*



# Co představuje jeden řádek?

**A**

Jednoho konkrétního geparda.

**B**

Jeden zastoupený druh savce.

**C**

Jednu hodinu měření.

Když nehlasujeme: doplňte větu „Jeden řádek této tabulky představuje ...“

# Jeden řádek = jeden zastoupený druh

## CO VÍME

Každá hodnota spánku patří jednomu **druhu**, který je v tabulce zastoupen.

## CO Z TOHO NEPLYNE

Tabulka neobsahuje hmotnosti nebo spánek všech jednotlivých savců na Zemi.

# Jak uložíme jednu hodnotu v R?

```
1 vec_spanek_ukazka <-  
2   c(  
3     12.1 # Cheetah  
4   )  
5  
6 vec_spanek_ukazka
```

```
[1] 12.1
```

## VEKTOR (*VECTOR*)

Vektor je uspořádaná řada hodnot stejného typu.

# Druhý řádek přidá druhou hodnotu

```
1 vec_spanek_ukazka <-  
2   c(  
3     12.1, # Cheetah  
4     17.0 # Owl monkey  
5   )  
6  
7 vec_spanek_ukazka
```

```
[1] 12.1 17.0
```

## CO ZNAMENÁ POŘADÍ?

První hodnota vektoru patří prvnímu řádku tabulky, druhá druhému řádku.

# Stejné čtyři hodnoty zapíšeme do vektoru

```
1 vec_spanek_ukazka <-  
2   c(  
3     12.1, # Cheetah  
4     17.0, # Owl monkey  
5     14.4, # Mountain beaver  
6     14.9 # Greater short-tailed shrew  
7   )
```

Tabulka uchovává i jména druhů. Samotný vektor uchovává jen hodnoty a jejich pořadí.

# Co zkontrolujeme dřív, než počítáme?

```
1 length(  
2   x = vec_spanek_ukazka  
3 )
```

```
[1] 4
```

`length()` říká, kolik hodnot máme.

```
1 head(  
2   x = vec_spanek_ukazka  
3 )
```

```
[1] 12.1 17.0 14.4 14.9
```

`head()` ukáže první hodnoty.

# Celá tabulka přidává další proměnné

## DATASET `msleep`

- **83 řádků:** zastoupené druhy savců;
- **5 sloupců:** například spánek, hmotnost, potrava nebo taxonomický řád;
- některé údaje chybějí, protože zdrojová tabulka není úplná.

Než popisujeme čísla, vždy si ujasníme **jednotku pozorování**, význam proměnné a jednotky měření.

# Od tabulky ke grafu




# Data přibývají druh po druhu

## 1 z 83 zastoupených druhů




Graf nevzniká místo dat. Vzniká postupným zobrazováním hodnot, které jsme vložili do tabulky a vektoru.

# Dva soubory vypadají jinak




*Ve kterém souboru jsou hodnoty rozptýlenější?*

# Jak vypadá spánek všech zastoupených druhů?



*Kde leží nejkratší a nejdelší doba spánku? Kde se body hromadí?*

# Body zachovají každý druh




## CO VIDÍME

- jednotlivé hodnoty;
- mezery a shluky;
- nejmenší a největší hodnotu.

## CO MŮŽE BÝT PROBLÉM


Ve velmi velkém souboru se body mohou překrývat.

# Stejná data, seskupená do intervalů



**Histogram** ukazuje počty v intervalech, ale skrývá přesné hodnoty jednotlivých druhů.

# Stejná data, ale jako hladký tvar



**Graf hustoty** zvýrazní tvar, ale neukazuje konkrétní počty ani jednotlivé druhy.

# Který graf byste použili?

**Potřebujete zjistit, zda některý druh spí téměř 20 hodin denně.**

**A**

Bodový graf

**B**

Histogram

**C**

Graf hustoty

Když nehlasujeme: napište si, který graf zachovává jednotlivé hodnoty a proč je to pro tuto otázku důležité.

# Tři grafy, tři různé otázky


| Graf         | Nejlépe ukáže       | Co skrývá                            |
|--------------|---------------------|--------------------------------------|
| Bodový graf  | jednotlivé hodnoty  | při velkém počtu může být přeplněný  |
| Histogram    | počty v intervalech | přesné hodnoty; závisí na šířce koše |
| Graf hustoty | hladký tvar         | počty a konkrétní druhy              |

Graf vybíráme podle otázky, ne podle toho, který vypadá nejmoderněji.




# Deskriptivní statistiky

# Devět druhů, devět dob spánku



*Kam byste umístili jeden bod, který má zastoupit všech devět hodnot?*

# Minimum: nejmenší pozorovaná hodnota




```
1 min(  
2   x = vec_spanek_deviti  
3 )
```

[1] 2.9

Minimum (*minimum*) je  
zde **2.9 h.**

# Maximum: největší pozorovaná hodnota




```
1 max(  
2     x = vec_spanek_deviti  
3 )
```

[1] 12.5

Maximum (*maximum*) je  
zde **12.5 h**.

Minimum a maximum ukazují krajní pozorované hodnoty. Neříkají, kde leží většina dat.

# Průměr: hodnoty sečteme a rozdělíme




Aritmetický průměr =  
**7,61 h**

```
1 vec_spanek_deviti <-  
2   c(  
3     2.9, 3.8, 4.0, 8.0, 8.4,  
4     9.1, 9.7, 10.1, 12.5  
5   )  
6  
7 mean(  
8   x = vec_spanek_deviti  
9 )
```

```
[1] 7.611111
```

**Aritmetický průměr (*mean*)** používá každou hodnotu a může být citlivý na hodnoty daleko od ostatních.

# Seřadíme hodnoty a hledáme prostřední



**Medián = 8,4 h**


```
1 median(  
2   x = vec_spanek_deviti  
3 )
```

```
[1] 8.4
```

Čtyři hodnoty leží níže a čtyři výše.

**Medián (*median*)** je prostřední hodnota seřazeného souboru.

# Kvartily rozdělí seřazené hodnoty na čtvrtiny




```
1 quantile(  
2   x = vec_spanek_deviti,  
3   probs = c(0.25, 0.75)  
4 )
```

25% 75%  
4.0 9.7

Q1 odděluje dolní čtvrtinu, Q3 horní čtvrtinu hodnot.

**Kvartily (*quartiles*) Q1 a Q3** určují hranice prostředních 50 % seřazených hodnot.

# IQR je šířka prostřední poloviny




```
1 IQR(  
2   x = vec_spanek_deviti  
3 )
```

```
[1] 5.7
```

**IQR (*interquartile range*) =  $Q3 - Q1$ .** Popisuje rozptýlení prostřední poloviny hodnot.



# Od průměru změříme odchylku každé hodnoty




## ODCHYLKA

**odchylka doby  
spánku =  
doba spánku druhu  
–  
průměrná doba  
spánku**

**Fialová** vede pod  
průměr, **oranžová**  
nad něj.

Délka barevného úseku ukazuje, jak daleko je každá hodnota od aritmetického průměru.

# U kočky dosadíme dvě čísla z grafu



## HODNOTY Z HORNÍHO ŘÁDKU

Kočka domácí: **12,5 h**


Aritmetický průměr: **7,61 h**

## DOSAZENÍ

$$12,5 \text{ h} - 7,61 \text{ h} = 4,89 \text{ h}$$

Kladný výsledek říká, že kočka domácí spí déle než průměr devíti druhů.

# Odchyly se navzájem vyruší




## SOUČET ODCHYLEK

**součet odchylek =  
kladné odchylky +  
záporné odchylky  
= 0,00 h**

Kolem průměru se  
navzájem vyváží.

**Když prostý součet vždy vyjde přibližně nula, jak zachováme velikost vzdáleností?**

# Odchyly umocníme na druhou



## ČTVERCOVÁ ODCHYLKA

čtvercová odchylka =  
odchylka × odchylka

$$4,89 \text{ h} \times 4,89 \text{ h} = \\ \mathbf{23,90 \text{ h}^2}$$

Všechny příspěvky jsou  
nezáporné.

Nejvíce zde přispívá kočka  
domácí, protože leží  
nejdále od průměru.

# Stejný krok rozepíšeme pro všech devět druhů

VŠECHNY HODNOTY JSOU PŘEVZATÉ Z GRAFU

$$\begin{aligned} &(2,9 - 7,61)^2 + (3,8 - 7,61)^2 + (4,0 - 7,61)^2 + \\ &(8,0 - 7,61)^2 + (8,4 - 7,61)^2 + (9,1 - 7,61)^2 + \\ &(9,7 - 7,61)^2 + (10,1 - 7,61)^2 + (12,5 - 7,61)^2 \\ &= 87,21 h^2 \end{aligned}$$

Nejdřív jsme rozepsali všech devět čtvercových odchylek; teprve potom jsme jejich součet zkrátili na jedno číslo.

# Rozptyl rozdělí součet

## NEJDŘÍV SLOVY

**výběrový rozptyl =  
součet čtvercových odchylek dělený  
počtem hodnot zmenšeným o jednu**

## POTOM DOSADÍME ČÍSLA

$$\begin{aligned}87,21 \text{ h}^2 / (9 - 1) &= \\87,21 \text{ h}^2 / 8 &= 10,90 \text{ h}^2\end{aligned}$$

Jednotkou rozptylu jsou **hodiny na druhou**. Proto se rozptyl hůře interpretuje přímo.

# Teprve teď zápis zkrátíme

## OBEČNÝ VZOREC

$$s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$$

```
1 var(  
2   x = vec_spanek_deviti  
3 )
```


```
[1] 10.90111
```

## CO ZNAMENAJÍ SYMBOLY?

- $s^2$  — výběrový rozptyl;
- $x_i$  — doba spánku jednoho druhu;
- $\bar{x}$  — aritmetický průměr;
- $n$  — počet hodnot;
- $\Sigma$  — sečteme příspěvky všech druhů.

Vzorec je jen krátký zápis postupu, který jsme už provedli slovy a s konkrétními čísly.

# Odmocnina vrátí výsledek do hodin



## NEJDŘÍV SLOVY

směrodatná odchylka =  
druhá odmocnina z rozptylu

## POTOM ČÍSLA

$$\sqrt{10,90 \text{ h}^2} = 3,30 \text{ h}$$

## NAKONEC KRÁTKÝ VZOREC


$$s = \sqrt{s^2}$$

$s$  je směrodatná odchylka a  $s^2$   
výběrový rozptyl.

V R stejný krok provede `sd(x = vec_spanek_deviti)`. **SD (*standard deviation*)** je  
zpět v původních jednotkách.



# Stejný průměr, jiné SD



Oba simulované soubory mají průměr 10. Větší SD odpovídá širšímu histogramu.

# Které souhrny patří k sobě?

**Vyberte dvojici, která popisuje střed a rozptýlení podobným způsobem.**

**A**

průměr + IQR

**B**

průměr + SD

**C**

medián + SD

Když nehlasujeme: napište si, která míra rozptýlení používá vzdálenosti od průměru.

# Dvě užitečné dvojice

## **PRŮMĚR + SD**

Používají všechny hodnoty a jsou citlivější k hodnotám daleko od středu.

## **MEDIÁN + IQR**

Vycházejí z pořadí hodnot a jsou odolnější vůči vzdáleným hodnotám.

Volbu neurčuje zvyk. Rozhoduje tvar dat a otázka, kterou souhrnem zodpovídáme.

**Zpět k titulku**

# Malý netopýr a velký slon jsou v jedné tabulce

Co znamená „běžná“ hmotnost?

## BIOLOGICKÁ OTÁZKA

Má jedno číslo zastoupit druhy od velmi malých savců až po slony?


Rozložení tělesné hmotnosti musíme vidět dřív, než vybereme souhrn.



Ilustrace vytvořená pomocí AI.


# Vracíme se k tělesné hmotnosti

# Lineární osa



Několik velmi těžkých druhů roztáhne osu tak silně, že většina bodů splývá u nuly.

# Stejná data na logaritmické ose



Graf nezměnil data. Jen nám dovolil vidět lehké i těžké druhy současně.

# Obě redakce počítaly správně

## TITULEK A

Průměr: **166 kg**

## TITULEK B

Medián: **1,67 kg**

**A)** Pouze A.

**B)** Pouze B.

**C)** Oba mohou být správně.

**D)** Nemáme dost informací.

Obě čísla jsou správně vypočtená. Ani jedno však není univerzální „typický savec“.



# Statistická redakce: opravte titulek

## DŮKAZY

- řádek představuje zastoupený **druh**, ne jednotlivého savce;
- rozdělení hmotnosti je silně pravostranně zešíkmené;
- průměr = 166 kg, medián = 1,67 kg.

**Přepište jeden titulek tak, aby byl pravdivý i po přečtení grafu.**

Když nepracujeme ve skupině: napište jednu větu, která uvádí souhrn, jednotku pozorování a omezení tabulky.

# Co z tabulky smíme tvrdit?

## POCTIVÝ ZÁVĚR


V této tabulce je medián hmotnosti zastoupeného druhu **1,67 kg**, ale několik velmi těžkých druhů posouvá průměr na **166 kg**.

## HRANICE ZÁVĚRU


Tabulka **není náhodným výběrem** všech druhů ani všech jednotlivých savců. Čísla proto nepopisují „náhodného savce na Zemi“.

# Statistiky jako vizualizace

# Začneme jednotlivými hodnotami a mediánem




# Přidáme prostřední polovinu




Šířka krabice je **IQR**: prostředních 50 % hodnot.

# Přidáme vousy



Body za vousy mohou být zajímavé nebo neobvyklé, ale nejsou automaticky chybné.

# Z bodů vznikl krabicový graf



Celkový spánek za den (h)


**Krabicový graf (*boxplot*)** je mapa několika souhrnů, ne fotografie všech hodnot.

# Co krabice schovala?

## Krabicový graf



## Krabicový + houslový graf



Když nehlasujeme: napište si jednu vlastnost rozdělení, kterou housle ukazují lépe než samotná krabice.



# Houslový graf vrací tvar

## KRABICOVÝ GRAF

Rychle porovná medián, IQR, vousy a možné odlehlé hodnoty.

## HOUSLOVÝ GRAF

Ukáže, kde se hodnoty hromadí, ale přesná četnost se z jeho šířky čte obtížně.

Housle mohou být informativnější, když je důležitý **tvar**; **body** zůstávají nejtransparentnější první kontrolou.

# Typy proměnných

# Jeden netopýr, různé typy údajů

U netopýra můžeme zaznamenat:

- dobu spánku v hodinách;
- počet pozorovaných jedinců;
- typ potravy;
- uměle vytvořenou velikostní kategorií.



Ilustrace vytvořená pomocí AI.

Typ neurčuje vzhled čísla. Určuje jej význam proměnné.

# Číslo 37 může znamenat čtyři různé věci

| Zápis | Co znamená           | Jak vznikl           |
|-------|----------------------|----------------------|
| 37,0  | tělesná teplota      | měření               |
| 37    | počet mlád'at        | počítání             |
| 37    | číselný kód lokality | název kategorie      |
| 3     | stupeň poškození     | uspořádaná kategorie |


Rozhoduje vzhled hodnoty, nebo její **význam**?

# Typ určuje význam a možné operace

- **spojitá numerická**: měření na číselné škále;
- **diskrétní numerická**: výsledek počítání;
- **nominální kategoriální**: názvy bez přirozeného pořadí;
- **ordinální kategoriální**: kategorie s přirozeným pořadím.

Technická třída objektu v R pomáhá s kontrolou, ale **statistický typ** určuje význam hodnot a způsob jejich vzniku.

# Doba spánku vznikla měřením



```
1 vec_spanek_h <-  
2   ggplot2::msleep[["sleep_total"]]  
3  
4 class(x = vec_spanek_h)
```


```
[1] "numeric"
```

```
1 typeof(x = vec_spanek_h)
```

```
[1] "double"
```

**Spojitá numerická  
proměnná**: mezi dvěma  
hodnotami mohou být další  
měření.

# Počet druhů v řádu jsme spočítali



```
1 vec_pocet_druhu <-  
2   as.integer(  
3     x = table(  
4       ggplot2::msleep[["order"]] )  
5   )  
6 )  
7  
8 class(x = vec_pocet_druhu)
```

```
[1] "integer"
```


```
1 str(object = vec_pocet_druhu)
```

```
int [1:19] 1 6 12 3 2 2 2 2 2 3 ...
```

## Diskrétní numerická

**proměnná**: vznikla  
**počítáním**; zde měníme  
jednotku pozorování na  
taxonomický řád.

# Typ potravy je název bez pořadí



```
1 vec_typ_potravy <-  
2   ggplot2::msleep[["vore"]]  
3  
4 vec_chybi <-  
5   is.na(vec_typ_potravy)  
6  
7 vec_typ_potravy[vec_chybi] <-  
8   "neuvedeno"  
9  
10 vec_typ_potravy <-  
11   factor(x = vec_typ_potravy)  
12  
13 class(x = vec_typ_potravy)
```

```
[1] "factor"
```


```
1 str(object = vec_typ_potravy)
```

```
Factor w/ 5 levels "carni","herbi",...: 1  
5 2 5 2 2 1 4 1 2 ...
```

**Nominální kategoriální proměnná:** smysl dávají četnosti a podíly, ne průměr kódů.



# Umělé pořadí: lehký–střední–těžký



```
1 poradi <-  
2   c("lehký", "střední", "těžký")  
3  
4 vec_velikost <-  
5   ordered(  
6     x = poradi,  
7     levels = poradi  
8   )  
9  
10 class(x = vec_velikost)
```

```
[1] "ordered" "factor"
```

```
1 str(object = vec_velikost)
```

```
Ord.factor w/ 3 levels "lehký"<"střední"  
<...: 1 2 3
```

**Ordinální kategoriální proměnná**: pořadí je součástí objektu, ale kategorie jsou pouze **didaktická pomůcka**.

# Určete typ a první graf

| Proměnná               | Jak vznikla?          |
|------------------------|-----------------------|
| pH vody v rybníce      | měřením               |
| počet mlád'at ve vrhu  | počítáním             |
| druh stanoviště        | názvem kategorie      |
| stupeň poškození listu | uspořádanou kategorií |

**Pro každou proměnnou určete typ a navrhnete první graf.**

Když nepracujeme ve skupině: vyberte jednu proměnnou a napište typ, vhodný souhrn a vhodný první graf.

# Od typu proměnné k prvnímu popisu

| Typ proměnné           | Vhodný první souhrn              | Vhodný první graf                    |
|------------------------|----------------------------------|--------------------------------------|
| numerická spojitá      | medián + IQR nebo<br>průměr + SD | body, histogram,<br>hustota, boxplot |
| numerická diskrétní    | četnosti; někdy<br>medián/průměr | body nebo sloupce<br>počtů           |
| kategoriální nominální | četnosti a podíly                | sloupcový graf                       |
| kategoriální ordinální | četnosti; někdy medián<br>pořadí | uspořádaný sloupcový<br>graf         |

Typ proměnné zužuje, které grafy, souhrny a později i modely dávají smysl.

# Závěr

# Shrnutí

- **Jeden řádek** nejdřív spojíme s jeho skutečnou jednotkou pozorování.
- **Graf čteme dříve**, než data nahradíme jedním číslem.
- **Průměr + SD**; **medián + IQR**.
- **Krabicový graf** je mapa souhrnů a může skrýt tvar.
- **Význam proměnné** určuje její typ, vhodný graf a vhodný souhrn.

# Co potřebujete vědět, než řeknete „typický“?

**Jaké tři otázky položíte člověku, který vám ukáže jedno souhrnné číslo bez grafu?**

V následující lekci přidáme druhou proměnnou a zeptáme se, zda spolu dvě měření souvisejí.