

Co váží „typický“ savec?

Biostatistika

 Ondřej Mottl

Moodle

Kolik váží běžný savec?

SMYŠLENÝ TITULEK A

Vědci spočítali:

„Průměrný (*mean*) savec váží **166 kg**.“

SMYŠLENÝ TITULEK B

Jiná analýza tvrdí:

„Běžný savec (*median*) váží jen **1,67 kg**.“

Stejná tabulka. Dvě dramaticky odlišná čísla.

Výsledky učení

Po dnešní přednášce budete schopni:

- vysvětlit, co v tabulce představuje **jeden řádek**
- přečíst vhodný **graf jedné proměnné**
- vybrat smysluplnou dvojici **středu** a **rozptýlení**
- rozlišit čtyři **typy proměnných** a zvolit jejich první popis
- vysvětlit, proč jedno správně vypočtené číslo ještě nemusí být dobrý titulek

Jak budeme dnes pracovat?

Otázka → data → graf → souhrn → opatrná interpretace

NA PŘEDNÁŠCE

Budete odhadovat, hlasovat,
porovnávat grafy a obhajovat závěry.

V MATERIÁLECH

HTML nabízí záložky a rozbalovací
otázky; PDF je vhodné pro souvislé
čtení.

Hlasování: který titulek je správný?

TITULEK A

„Průměrný savec váží **166 kg.**“

TITULEK B

„Běžný savec váží **1,67 kg.**“

Nejdřív hlasujte sami. Potom svoji volbu obhájte sousedovi.

A) Pouze titulek A.

B) Pouze titulek B.

C) Oba mohou být správně.

D) Zatím nemáme dost informací.

Když nehlasujeme: napište si jednu informaci, kterou potřebujete znát, než titulku uvěříte.

Přesvědčte souseda

Proč jste vybrali právě svoji možnost?

DŮKAZ, KTERÝ MÁTE K DISPOZICI

- stejná tabulka savců;
- 166 kg versus 1,67 kg;
- zatím nevíme, jak hodnoty vypadají.

Odpověď zatím odložíme

Nejdřív zjistíme, **co bylo změřeno** a **jak hodnoty vypadají**.

Správný výpočet ještě nezaručuje správnou interpretaci.

Od organismu k datům

Začneme jedním savcem

Gepard (*Cheetah*)

Výzkumníci studovali spánkové návyky savců a u geparda zaznamenali **12.1 hodiny spánku za den**.

PŘI ZÁZNAMU MĚŘENÍ

Výsledek pro jeden zastoupený druh zapíšeme do jednoho řádku tabulky.



Ilustrace vytvořená pomocí AI.

První pozorování přidá první řádek

Druh (species)	Spánek za den (h)
Cheetah	12.1

Jeden řádek zachovává spojení mezi **druhem** a jeho **hodnotou**.

Další druh přidá další řádek

Druh (species)	Spánek za den (h)
Cheetah	12.1
Owl monkey	17.0

Tabulka roste **po řádcích**: jeden zastoupený druh po druhém.

Čtyři druhy, čtyři řádky

Druh (species)	Spánek za den (h)
Cheetah	12.1
Owl monkey	17.0
Mountain beaver	14.4
Greater short-tailed shrew	14.9

Na co přesně se vztahuje hodnota 12,1 hodiny v prvním řádku?

Co představuje jeden řádek?

A

Jednoho konkrétního geparda.

B

Jeden zastoupený druh savce.

C

Jednu hodinu měření.

Když nehlasujeme: doplňte větu „Jeden řádek této tabulky představuje ...“

Jeden řádek = jeden zastoupený druh

CO VÍME

Každá hodnota spánku patří jednomu **druhu**, který je v tabulce zastoupen.

CO Z TOHO NEPLYNE

Tabulka neobsahuje hmotnosti nebo spánek všech jednotlivých savců na Zemi.

Jak uložíme jednu hodnotu v R?

```
1 vec_spanek_ukazka <-  
2   c(  
3     12.1 # Cheetah  
4   )  
5  
6 vec_spanek_ukazka
```

```
[1] 12.1
```

VEKTOR (*VECTOR*)

Vektor je uspořádaná řada hodnot stejného typu.

Druhý řádek přidá druhou hodnotu

```
1 vec_spanek_ukazka <-  
2   c(  
3     12.1, # Cheetah  
4     17.0 # Owl monkey  
5   )  
6  
7 vec_spanek_ukazka
```

```
[1] 12.1 17.0
```

CO ZNAMENÁ POŘADÍ?

První hodnota vektoru patří prvnímu řádku tabulky, druhá druhému řádku.

Stejné čtyři hodnoty zapíšeme do vektoru

```
1 vec_spanek_ukazka <-  
2   c(  
3     12.1, # Cheetah  
4     17.0, # Owl monkey  
5     14.4, # Mountain beaver  
6     14.9 # Greater short-tailed shrew  
7   )
```

Tabulka uchovává i jména druhů. Samotný vektor uchovává jen hodnoty a jejich pořadí.

Co zkontrolujeme dřív, než počítáme?

```
1 length(  
2   x = vec_spanek_ukazka  
3 )
```

```
[1] 4
```

`length()` říká, kolik hodnot máme.

```
1 head(  
2   x = vec_spanek_ukazka  
3 )
```

```
[1] 12.1 17.0 14.4 14.9
```

`head()` ukáže první hodnoty.

Celá tabulka přidává další proměnné

DATASET `msleep`

- **83 řádků:** zastoupené druhy savců;
- **5 sloupců:** například spánek, hmotnost, potrava nebo taxonomický řád;
- některé údaje chybějí, protože zdrojová tabulka není úplná.

Než popisujeme čísla, vždy si ujasníme **jednotku pozorování**, význam proměnné a jednotky měření.

Od tabulky ke grafu


Data přibývají druh po druhu

1 z 83 zastoupených druhů




Graf nevzniká místo dat. Vzniká postupným zobrazením hodnot, které jsme vložili do tabulky a vektoru.

Dva soubory vypadají jinak




Ve kterém souboru jsou hodnoty rozptýlenější?

Jak vypadá spánek všech zastoupených druhů?



Kde leží nejkratší a nejdelší doba spánku? Kde se body hromadí?

Body zachovají každý druh




CO VIDÍME

- jednotlivé hodnoty;
- mezery a shluky;
- nejmenší a největší hodnotu.

CO MŮŽE BÝT PROBLÉM


Ve velmi velkém souboru se body mohou překrývat.

Stejná data, seskupená do intervalů



Histogram ukazuje počty v intervalech, ale skrývá přesné hodnoty jednotlivých druhů.

Stejná data, ale jako hladký tvar



Graf hustoty zvýrazní tvar, ale neukazuje konkrétní počty ani jednotlivé druhy.

Který graf byste použili?

Potřebujete zjistit, zda některý druh spí téměř 20 hodin denně.

A

Bodový graf

B

Histogram

C

Graf hustoty

Když nehlasujeme: napište si, který graf zachovává jednotlivé hodnoty a proč je to pro tuto otázku důležité.


Tři grafy, tři různé otázky

Graf	Nejlépe ukáže	Co skrývá
Bodový graf	jednotlivé hodnoty	při velkém počtu může být přeplněný
Histogram	počty v intervalech	přesné hodnoty; závisí na šířce koše
Graf hustoty	hladký tvar	počty a konkrétní druhy

Graf vybíráme podle otázky, ne podle toho, který vypadá nejmoderněji.


Deskriptivní statistiky

Devět druhů, devět dob spánku



Kam byste umístili jeden bod, který má zastoupit všech devět hodnot?

Minimum: nejmenší pozorovaná hodnota




```
1 min(  
2   x = vec_spanek_deviti  
3 )
```

[1] 2.9

Minimum (*minimum*) je
zde **2.9 h.**

Maximum: největší pozorovaná hodnota




```
1 max(  
2   x = vec_spanek_deviti  
3 )
```

[1] 12.5

Maximum (*maximum*) je
zde **12.5 h**.

Minimum a maximum ukazují krajní pozorované hodnoty. Neříkají, kde leží většina dat.

Průměr: hodnoty sečteme a rozdělíme




Aritmetický průměr =
7,61 h

```
1 vec_spanek_deviti <-  
2   c(  
3     2.9, 3.8, 4.0, 8.0, 8.4,  
4     9.1, 9.7, 10.1, 12.5  
5   )  
6  
7 mean(  
8   x = vec_spanek_deviti  
9 )
```

```
[1] 7.611111
```

Aritmetický průměr (*mean*) používá každou hodnotu a může být citlivý na hodnoty daleko od ostatních.

Seřadíme hodnoty a hledáme prostřední



Medián = 8,4 h


```
1 median(  
2   x = vec_spanek_deviti  
3 )
```

```
[1] 8.4
```

Čtyři hodnoty leží níže a čtyři výše.

Medián (*median*) je prostřední hodnota seřazeného souboru.

Kvartily rozdělí seřazené hodnoty na čtvrtiny




```
1 quantile(  
2   x = vec_spanek_deviti,  
3   probs = c(0.25, 0.75)  
4 )
```

25% 75%
4.0 9.7

Q1 odděluje dolní
čtvrtinu, Q3 horní
čtvrtinu hodnot.

Kvartily (*quartiles*) Q1 a Q3 určují hranice prostředních 50 % seřazených hodnot.

IQR je šířka prostřední poloviny




```
1 IQR(  
2   x = vec_spanek_deviti  
3 )
```

```
[1] 5.7
```

IQR (*interquartile range*) = Q3 – Q1. Popisuje rozptýlení prostřední poloviny hodnot.

Od průměru změříme odchylku každé hodnoty




ODCHYLKA

**odchylka doby
spánku =
doba spánku druhu
–
průměrná doba
spánku**

Fialová vede pod
průměr, **oranžová**
nad něj.

Délka barevného úseku ukazuje, jak daleko je každá hodnota od aritmetického průměru.

U kočky dosadíme dvě čísla z grafu



HODNOTY Z HORNÍHO ŘÁDKU

Kočka domácí: **12,5 h**


Aritmetický průměr: **7,61 h**

DOSAZENÍ

$$12,5 \text{ h} - 7,61 \text{ h} = 4,89 \text{ h}$$

Kladný výsledek říká, že kočka domácí spí déle než průměr devíti druhů.

Odchyly se navzájem vyruší




SOUČET ODCHYLEK

**součet odchylek =
kladné odchylky +
záporné odchylky
= 0,00 h**

Kolem průměru se
navzájem vyváží.

Když prostý součet vždy vyjde přibližně nula, jak zachováme velikost vzdáleností?

Odchyly umocníme na druhou



ČTVERCOVÁ ODCHYLKA

čtvercová odchylka =
odchylka × odchylka

$$4,89 \text{ h} \times 4,89 \text{ h} =$$
$$23,90 \text{ h}^2$$

Všechny příspěvky jsou
nezáporné.

Nejvíce zde přispívá kočka
domácí, protože leží
nejdále od průměru.

Stejný krok rozepíšeme pro všech devět druhů

VŠECHNY HODNOTY JSOU PŘEVZATÉ Z GRAFU

$$\begin{aligned} &(2,9 - 7,61)^2 + (3,8 - 7,61)^2 + (4,0 - 7,61)^2 + \\ &(8,0 - 7,61)^2 + (8,4 - 7,61)^2 + (9,1 - 7,61)^2 + \\ &(9,7 - 7,61)^2 + (10,1 - 7,61)^2 + (12,5 - 7,61)^2 \\ &= 87,21 h^2 \end{aligned}$$

Nejdřív jsme rozepsali všech devět čtvercových odchylek; teprve potom jsme jejich součet zkrátili na jedno číslo.

Rozptyl rozdělí součet

NEJDŘÍV SLOVY

**výběrový rozptyl =
součet čtvercových odchylek dělený
počtem hodnot zmenšeným o jednu**

POTOM DOSADÍME ČÍSLA

$$\begin{aligned}87,21 \text{ h}^2 / (9 - 1) &= \\87,21 \text{ h}^2 / 8 &= 10,90 \text{ h}^2\end{aligned}$$

Jednotkou rozptylu jsou **hodiny na druhou**. Proto se rozptyl hůře interpretuje přímo.

Teprve teď zápis zkrátíme

OBEČNÝ VZOREC

$$s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$$

```
1 var(  
2   x = vec_spanek_deviti  
3 )
```


```
[1] 10.90111
```

CO ZNAMENAJÍ SYMBOLY?

- s^2 — výběrový rozptyl;
- x_i — doba spánku jednoho druhu;
- $\bar{x}$ — aritmetický průměr;
- n — počet hodnot;
- Σ — sečteme příspěvky všech druhů.

Vzorec je jen krátký zápis postupu, který jsme už provedli slovy a s konkrétními čísly.

Odmocnina vrátí výsledek do hodin



NEJDŘÍV SLOVY

směrodatná odchylka =
druhá odmocnina z rozptylu

POTOM ČÍSLA

$$\sqrt{10,90 \text{ h}^2} = 3,30 \text{ h}$$


NAKONEC KRÁTKÝ VZOREC

$$s = \sqrt{s^2}$$

s je směrodatná odchylka a s^2
výběrový rozptyl.

V R stejný krok provede `sd(x = vec_spanek_deviti)`. **SD (*standard deviation*)** je zpět v původních jednotkách.

Stejný průměr, jiné SD



Oba simulované soubory mají průměr 10. Větší SD odpovídá širšímu histogramu.

Které souhrny patří k sobě?

Vyberte dvojici, která popisuje střed a rozptýlení podobným způsobem.

A

průměr + IQR

B

průměr + SD

C

medián + SD

Když nehlasujeme: napište si, která míra rozptýlení používá vzdálenosti od průměru.

Dvě užitečné dvojice

PRŮMĚR + SD

Používají všechny hodnoty a jsou citlivější k hodnotám daleko od středu.

MEDIÁN + IQR

Vycházejí z pořadí hodnot a jsou odolnější vůči vzdáleným hodnotám.

Volbu neurčuje zvyk. Rozhoduje tvar dat a otázka, kterou souhrnem zodpovídáme.

Zpět k titulku

Malý netopýr a velký slon jsou v jedné tabulce

Co znamená „běžná“
hmotnost?

BIOLOGICKÁ OTÁZKA

Má jedno číslo zastoupit druhy od
velmi malých savců až po slony?


Rozložení tělesné hmotnosti
musíme vidět dřív, než
vybereme souhrn.



Ilustrace vytvořená pomocí AI.


Vracíme se k tělesné hmotnosti

Lineární osa



Několik velmi těžkých druhů roztáhne osu tak silně, že většina bodů splývá u nuly.

Stejná data na logaritmické ose



Graf nezměnil data. Jen nám dovolil vidět lehké i těžké druhy současně.

Obě redakce počítaly správně

TITULEK A

Průměr: **166 kg**

TITULEK B

Medián: **1,67 kg**

A) Pouze A.

B) Pouze B.

C) Oba mohou být správně.

D) Nemáme dost informací.

Obě čísla jsou správně vypočtená. Ani jedno však není univerzální „typický savec“.

Statistická redakce: opravte titulek

DŮKAZY

- řádek představuje zastoupený **druh**, ne jednotlivého savce;
- rozdělení hmotnosti je silně pravostranně zešíkmené;
- průměr = 166 kg, medián = 1,67 kg.

Přepište jeden titulek tak, aby byl pravdivý i po přečtení grafu.

Když nepracujeme ve skupině: napište jednu větu, která uvádí souhrn, jednotku pozorování a omezení tabulky.

Co z tabulky smíme tvrdit?

POCTIVÝ ZÁVĚR


V této tabulce je medián hmotnosti zastoupeného druhu **1,67 kg**, ale několik velmi těžkých druhů posouvá průměr na **166 kg**.

HRANICE ZÁVĚRU


Tabulka **není náhodným výběrem** všech druhů ani všech jednotlivých savců. Čísla proto nepopisují „náhodného savce na Zemi“.

Statistiky jako vizualizace

Začneme jednotlivými hodnotami a mediánem




Přidáme prostřední polovinu



Šířka krabice je **IQR**: prostředních 50 % hodnot.


Přidáme vousy



Celkový spánek za den (h)

Body za vousy mohou být zajímavé nebo neobvyklé, ale nejsou automaticky chybné.

Z bodů vznikl krabicový graf



Celkový spánek za den (h)


Krabicový graf (*boxplot*) je mapa několika souhrnů, ne fotografie všech hodnot.

Co krabice schovala?

Krabicový graf



Krabicový + houslový graf



Když nehlasujeme: napište si jednu vlastnost rozdělení, kterou housle ukazují lépe než samotná krabice.

Houslový graf vrací tvar

KRABICOVÝ GRAF

Rychle porovná medián, IQR, vousy a možné odlehlé hodnoty.

HOUSLOVÝ GRAF

Ukáže, kde se hodnoty hromadí, ale přesná četnost se z jeho šířky čte obtížně.

Housle mohou být informativnější, když je důležitý **tvar**; **body** zůstávají nejtransparentnější první kontrolou.

Typy proměnných

Jeden netopýr, různé typy údajů

U netopýra můžeme zaznamenat:

- dobu spánku v hodinách;
- počet pozorovaných jedinců;
- typ potravy;
- uměle vytvořenou velikostní kategorií.



Ilustrace vytvořená pomocí AI.

Typ neurčuje vzhled čísla. Určuje jej význam proměnné.

Číslo 37 může znamenat čtyři různé věci

Zápis	Co znamená	Jak vznikl
37,0	tělesná teplota	měření
37	počet mlád'at	počítání
37	číselný kód lokality	název kategorie
3	stupeň poškození	uspořádaná kategorie


Rozhoduje vzhled hodnoty, nebo její **význam**?

Typ určuje význam a možné operace

- **spojitá numerická**: měření na číselné škále;
- **diskrétní numerická**: výsledek počítání;
- **nominální kategoriální**: názvy bez přirozeného pořadí;
- **ordinální kategoriální**: kategorie s přirozeným pořadím.

Technická třída objektu v R pomáhá s kontrolou, ale **statistický typ** určuje význam hodnot a způsob jejich vzniku.

Doba spánku vznikla měřením



```
1 vec_spanek_h <-  
2   ggplot2::msleep[["sleep_total"]]  
3  
4   class(x = vec_spanek_h)
```


```
[1] "numeric"
```

```
1   typeof(x = vec_spanek_h)
```

```
[1] "double"
```

**Spojitá numerická
proměnná**: mezi dvěma
hodnotami mohou být další
měření.

Počet druhů v řádu jsme spočítali



```
1 vec_pocet_druhu <-  
2   as.integer(  
3     x = table(  
4       ggplot2::msleep[["order"]]  
5     )  
6   )  
7  
8 class(x = vec_pocet_druhu)
```

```
[1] "integer"
```


```
1 str(object = vec_pocet_druhu)
```

```
int [1:19] 1 6 12 3 2 2 2 2 2 3 ...
```

Diskrétní numerická

proměnná: vznikla
počítáním; zde měníme
jednotku pozorování na
taxonomický řád.

Typ potravy je název bez pořadí



```
1 vec_typ_potravy <-  
2   ggplot2::msleep[["vore"]]  
3  
4 vec_chybi <-  
5   is.na(vec_typ_potravy)  
6  
7 vec_typ_potravy[vec_chybi] <-  
8   "neuvedeno"  
9  
10 vec_typ_potravy <-  
11   factor(x = vec_typ_potravy)  
12  
13 class(x = vec_typ_potravy)
```


```
[1] "factor"
```

```
1 str(object = vec_typ_potravy)
```

```
Factor w/ 5 levels "carni","herbi",...: 1  
5 2 5 2 2 1 4 1 2 ...
```

Nominální kategoriální proměnná: smysl dávají četnosti a podíly, ne průměr kódů.

Umělé pořadí: lehký–střední–těžký



```
1 poradi <-  
2   c("lehký", "střední", "těžký")  
3  
4 vec_velikost <-  
5   ordered(  
6     x = poradi,  
7     levels = poradi  
8   )  
9  
10 class(x = vec_velikost)
```

```
[1] "ordered" "factor"
```

```
1 str(object = vec_velikost)
```

```
Ord.factor w/ 3 levels "lehký"<"střední"  
<...: 1 2 3
```

Ordinální kategoriální proměnná: pořadí je součástí objektu, ale kategorie jsou pouze **didaktická pomůcka**.

Určete typ a první graf

Proměnná	Jak vznikla?
pH vody v rybníce	měřením
počet mlád'at ve vrhu	počítáním
druh stanoviště	názvem kategorie
stupeň poškození listu	uspořádanou kategorií

Pro každou proměnnou určete typ a navrhnete první graf.

Když nepracujeme ve skupině: vyberte jednu proměnnou a napište typ, vhodný souhrn a vhodný první graf.

Od typu proměnné k prvnímu popisu

Typ proměnné	Vhodný první souhrn	Vhodný první graf
numerická spojitá	medián + IQR nebo průměr + SD	body, histogram, hustota, boxplot
numerická diskrétní	četnosti; někdy medián/průměr	body nebo sloupce počtů
kategoriální nominální	četnosti a podíly	sloupcový graf
kategoriální ordinální	četnosti; někdy medián pořadí	uspořádaný sloupcový graf

Typ proměnné zužuje, které grafy, souhrny a později i modely dávají smysl.

Závěr

Shrnutí

- **Jeden řádek** nejdřív spojíme s jeho skutečnou jednotkou pozorování.
- **Graf čteme dříve**, než data nahradíme jedním číslem.
- **Průměr + SD**; **medián + IQR**.
- **Krabicový graf** je mapa souhrnů a může skrýt tvar.
- **Význam proměnné** určuje její typ, vhodný graf a vhodný souhrn.

Co potřebujete vědět, než řeknete „typický“?

Jaké tři otázky položíte člověku, který vám ukáže jedno souhrnné číslo bez grafu?

V následující lekci přidáme druhou proměnnou a zeptáme se, zda spolu dvě měření souvisejí.