

Vizualizace dat a deskriptivní statistika

Biostatistika - L-example



Ondřej Mottl

[Moodle](#)

Výsledky učení

Po absolvování této přednášky budete schopni:

- Rozlišit typy proměnných
- Zvolit odpovídající popis dat (deskriptivní statistiky)
- Zvolit vhodnou vizualizaci dat (grafy)

Naše data

Kopretiny



Photo by [Pixabay](#)

Kopretiny

Vydáme se na louku a začneme sbírat kopretiny.

U každé kopretiny si zapíšeme **počet okvětních lístků**.

Kopretiny

Zapisujeme si počet okvětních lístků u kopretiny. Můžeme mít 5, 6, 7, 8, ... lístků.

Květina	Počet lístků
A	8

Kopretiny

Zapisujeme si počet okvětních lístků u kopretiny. Můžeme mít 5, 6, 7, 8, ... lístků.

Květina	Počet lístků
A	8
B	6

Kopretiny

Zapisujeme si počet okvětních lístků u kopretiny. Můžeme mít 5, 6, 7, 8, ... lístků.

Květina	Počet lístků
A	8
B	6
C	7

Kopretiny

Zapisujeme si počet okvětních lístků u kopretiny. Můžeme mít 5, 6, 7, 8, ... lístků.

Květina	Počet lístků
A	8
B	6
C	7
D	8

Kopretiny

Zapisujeme si počet okvětních lístků u kopretiny. Můžeme mít 5, 6, 7, 8, ... lístků.

Květina	Počet lístků
A	8
B	6
C	7
D	8
...	...

Kopretiny

```
1 pocet_listku <-  
2   c(  
3     8 # květina A  
4   )
```

Květina	Počet lístků
---------	--------------

A	8
---	---

Kopretiny

```
1 pocet_listku <-  
2   c(  
3     8, # květina A  
4     6 # květina B  
5   )
```

Květina	Počet lístků
A	8
B	6

Kopretiny

```
1 pocet_listku <-  
2   c(  
3     8, # květina A  
4     6, # květina B  
5     7, # květina C  
6     8, # květina D  
7     ... # další květiny  
8   )
```

Květina	Počet lístků
A	8
B	6
C	7
D	8
...	...


Kopretiny

Nasbírali jsme 100 kopretin a zapsali počet lístků u každé z nich.

Počet nasbíraných kopretin: 1



Kopretiny



Kopretiny

Nyní máme data. Jak je vizualizovat?

Vizualizace dat

Proč nejdřív vizualizovat?

Mám dvě skupiny kopretin. Obě mají **průměrný počet lístků 7**:

```
1 # Průměr skupiny A
2 mean(c(5, 6, 6, 7, 7, 7, 8, 8, 9))
```


```
[1] 7
```

```
1 # Průměr skupiny B
2 mean(c(4, 4, 5, 5, 7, 9, 9, 10, 10))
```

```
[1] 7
```

Proč nejdřív vizualizovat?

Stejný průměr — ale úplně jiný tvar dat




Skupina A má hodnoty soustředěné kolem 7 – symetrická, kompaktní. Skupina B má hodnoty spíše na okrajích – buď malá, nebo velká, málokdy průměrná. **Stejné číslo, zásadně odlišná biologie.**

Proč nejdřív vizualizovat?

Vždy nejdřív vizualizujte.

Bodový graf (beeswarm)


Každý bod = jedna kopretina. Vidíme **všechna data** najednou.



- vidíme **každou hodnotu zvlášť**
- odhaluje **tvar distribuce** (kde jsou hodnoty nahloubené)
- snadno odhalí **odlehlé hodnoty**

Histogram


Skupinujeme kopretiny do „košů“ podle počtu lístků. Výška sloupce = počet kopretin v daném koši.



- ukazuje, kde jsou hodnoty **nahroučené**
- odhaluje **symetrii** nebo **asymetrii** distribuce
- závisí na šířce koše (**binwidth**) – vyzkoušejte různé hodnoty

Graf hustoty

Graf hustoty (density plot) je „vyhlazený“ histogram – neukazuje počty, ale **relativní četnost** hodnot.



- „vyhlazená“ verze histogramu – nezávisí na šířce koše
- ukazuje **relativní četnost**: kde jsou hodnoty pravděpodobnější
- vhodný pro porovnání **více skupin** najednou

Deskriptivní statistiky

Deskriptivní statistiky


Minimum

Minimum nám říká, kolik lístků měla ta kopretina s nejmenším počtem lístků.

```
1 min(pocet_listku)
```

```
[1] 3
```

Minimum lístků: 3



Deskriptivní statistiky


Maximum

Maximum nám říká, kolik lístků měla ta kopretina s největším počtem lístků.

```
1 max(pocet_listku)
```

```
[1] 12
```

Maximum lístků: 12



Percentily

Percentil říká, jakou hodnotu nepřesahuje dané procento dat.

- **0. percentil** = minimum
- **50. percentil** = polovina kopretin má méně, polovina více
- **100. percentil** = maximum

```
1 quantile(pocet_listku, probs = c(0, 0.25, 0.50, 0.75, 1))
```

0%	25%	50%	75%	100%
3.00	6.75	7.00	8.00	12.00

Percentily rozdělují data na části – 25. a 75. percentil jsou zvláště důležité.

Deskriptivní statistiky


Medián

Medián je **50. percentil** – polovina kopretin má méně lístků, polovina více.

```
1 median(pocet_listku)
```

```
[1] 7
```

Medián lístků: 7



Mezikvartilové rozpětí (IQR)

Q1 = 25. percentil, **Q3** = 75. percentil.

IQR = **Q3** - **Q1** – rozpětí prostřední poloviny dat.

```
1 quantile(pocet_listku, 0.25) # Q1
```

25%

6.75

```
1 quantile(pocet_listku, 0.75) # Q3
```


75%

8

```
1 IQR(pocet_listku) # Q3 - Q1
```

[1] 1.25

Q1: 6.75, Q3: 8, IQR: 1.25



IQR je odolný vůči odlehlým hodnotám – popisuje **prostřední 50 %** dat.

Deskriptivní statistiky


Průměr

Průměr (mean) nám říká, jaká je typická hodnota počtu lístků přes všechny kopretiny.

```
1 mean(pocet_listku)
```

```
[1] 7.43
```

Průměr lístků: 7.4



Průměr vs. Medián

Průměr a medián mohou být velmi odlišné, pokud jsou v datech **odlehlé hodnoty** (outliers).

Co kdybychom sebrali opravdu divnou kopretinu s 50 lístky?

```
1 mean(pocet_listku)
```

```
[1] 7.43
```

```
1 median(pocet_listku)
```

```
[1] 7
```

```
1 mean(pocet_listku_outlier)
```

```
[1] 7.851485
```

```
1 median(pocet_listku_outlier)
```

```
[1] 7
```

Bez odlehlé hodnoty

S odlehlou hodnotou

Průměr je citlivý na odlehlé hodnoty. Medián je odolnější – popisuje „typický“ případ lépe, pokud data nejsou symetrická.

Rozptyl a směrodatná odchylka

Min, max, průměr a medián nám říkají, kde jsou data. Ale jak moc jsou data **rozptýlena**?

Směrodatná odchylka (standard deviation) nám říká, jak daleko jsou typicky hodnoty od průměru.

```
1 sd(pocet_listku)
```


```
[1] 1.51927
```

```
1 var(pocet_listku)
```

```
[1] 2.308182
```


Rozptyl (variance) = SD^2 . V praxi se většinou používá SD – je ve stejných jednotkách jako data

Průměr: 7.4, SD: 1.5



Proč je SD důležité?

Dvě skupiny kopretin mohou mít **stejný průměr**, ale velmi **různě rozptýlená data**.





Stejný průměr $\neq$ stejná data. Směrodatná odchylka nám říká, jak moc jsou data „roztažená“.

Statistiky jako vizualizace

Od statistik ke grafu

Průměr – SD jsme viděli jako čísla a jako pásmo na grafu.

Průměr: 7.4, SD: 1.5




Od statistik ke grafu

Co kdybychom statistiky nakreslili jako tvar?

Krabicový graf (boxplot) – krok 1

Začneme s tím, co už známe: **medián**.


Medián: 7



Krabicový graf (boxplot) – krok 2

Přidáme mezikvartilové rozpětí (IQR): od 25. do 75. percentilu.


Medián: 7, Q1: 6.75, Q3: 8, IQR: 1.25



Krabicový graf (boxplot) – krok 3

Přidáme **vousy** ($1,5 \times \text{IQR}$ od krabice) a **odlehlé hodnoty** (body mimo vousy).

Medián + IQR + vousy + odlehlé hodnoty




- Tlustá čára = **medián**
- Krabice = **IQR** (Q1–Q3)
- Vousy = $1,5 \times \text{IQR}$ od krabice
- Body = **odlehlé hodnoty**

Toto je standardní ggplot2 boxplot – totéž, akorát nakreslený automaticky.

Krabicový graf + surová data

Boxplot + beeswarm dohromady: vidíme statistiky i každý jednotlivý bod.



Boxplot není nový koncept – je to jen statistiky, které znáte, nakreslený jako tvar.

Typy proměnných

Proč rozlišujeme typy proměnných?

Typ proměnné určuje:

- jaké **statistiky** dávají smysl (průměr lístků ano; průměr barvy květu ne)
- jakou **vizualizaci** zvolíme (beeswarm pro čísla, sloupcový graf pro kategorie)
- jak data správně **interpretujeme**

Kvantitativní – diskrétní

- počet okvětních lístků u kopretiny
- počet stromů v lese
- počet druhů ptáků na lokalitě
- počet planet ve Sluneční soustavě

Proměnná nabývající pouze **celočíselných** hodnot – nelze mít 7,3 stromu.

Kvantitativní – diskrétní

```
1 pocet_listku <-  
2   c(8L, 6L, 7L, 8L) # celá čísla
```

Vizualizace: beeswarm nebo histogram.



Kvantitativní – spojitá

- délka okvětního lístku v mm
- teplota vzduchu
- množství srážek
- hmotnost zvířete


Proměnná nabývající **jakékoli hodnoty** v intervalu – délka může být 24,7 mm nebo 25,13 mm.

Kvantitativní – spojitá


```
1 delka_listku <-  
2   c(24.7, 25.1, 23.5, 26.8) # desetinná čísla
```

Různé vizualizace odhalují různé vlastnosti dat.


Bodový graf



Histogram



Graf hustoty



Kategorická – nominální


- barva květu (bílá, žlutá, fialová)
- druh hmyzu (včela, čmelák, motýl)
- typ stanoviště (les, louka, mokřad)
- krevní skupina (A, B, AB, 0)

Proměnná, jejíž hodnoty **nelze seřadit** – „šedá“ není víc ani méně než „žlutá“.

Kategorická – nominální

```
1 barva_kvetiny <-  
2   c("šedá", "žlutá", "šedá", "fialová")
```


Každá kategorie dostane vlastní barvu – vizuální kód odpovídá realitě.




Kategorická – nominální

Chceme ukázat **proporce** (ne počty)? Použijeme složený sloupcový graf nebo waffle.

Složený sloupcový graf



Waffle graf (1 čtverec



fialová šedá žlutá

Kategorická – ordinální

- stupeň poškození listu (žádné, mírné, střední, silné)
- školní klasifikace (1, 2, 3, 4, 5)
- souhlas s výrokiem (zcela souhlasím – zcela nesouhlasím)
- fáze měsíce (nový – úplněk)

Proměnná s **pořadím**, ale vzdálenost mezi stupni **není nutně stejná** – „střední“ poškození není přesně dvakrát větší než „mírné“.

Kategorická – ordinální

```
1 stupen_poskozeni <-  
2   factor(  
3     c("mírné", "silné", "žádné", "střední"),  
4     levels = c("žádné", "mírné", "střední", "silné"),  
5     ordered = TRUE  
6   )
```

Vizualizace: sloupcový graf s seřazenou osou.

